

Algoritmos Genéticos: Fundamentos y Formalización Matemática

Luis Alfredo Ramírez Maza

Junio 2025

Resumen

Estas notas desarrollan los fundamentos matemáticos de los algoritmos genéticos (AG) desde una perspectiva rigurosa. Se introducen formalmente los conceptos de cromosoma, población, función de aptitud y operadores genéticos (selección, cruce y mutación), y se presenta el algoritmo genético canónico como un proceso estocástico en un espacio de poblaciones. La parte central de las notas está dedicada al *Teorema de los Esquemas* de Holland, que proporciona la única garantía analítica clásica sobre el comportamiento del algoritmo en términos de la propagación de subestructuras favorables. Se discuten además convergencia, paisajes de aptitud, y extensiones modernas del modelo canónico.

Índice

1. Introducción y motivación	3
2. Representación: cromosomas y espacios de búsqueda	3
2.1. El alfabeto y el cromosoma	3
2.2. Genotipo, fenotipo y función de decodificación	4
3. Función de aptitud y paisaje de aptitud	4
4. Población y modelo probabilístico	5
5. Operadores genéticos	5
5.1. Selección	6
5.2. Cruce (recombinación)	7
5.3. Mutación	8
6. El algoritmo genético canónico	9
7. Esquemas: subestructuras y bloques constructores	10
7.1. Definición y propiedades de los esquemas	10
7.2. El Teorema de los Esquemas	11
7.3. Paralelismo implícito	12
8. Hipótesis de los bloques constructores	12
9. Análisis de convergencia	13
9.1. El AG como cadena de Markov	13
9.2. Pérdida de diversidad y convergencia prematura	14
9.3. No Free Lunch	14
10. Dinámica poblacional y modelos continuos	14
11. Extensiones y variantes del modelo canónico	15
11.1. Estrategias evolutivas $(\mu + \lambda$ y $\mu, \lambda)$	15
11.2. Algoritmos genéticos para optimización multiobjetivo	15
11.3. Algoritmos de estimación de distribuciones (EDA)	15
11.4. AG multimodales y niching (compartición de aptitud)	16

1. Introducción y motivación

Los algoritmos genéticos son métodos de búsqueda y optimización inspirados en los mecanismos de la evolución biológica. Fueron formalizados por John Holland en la década de 1970 y constituyen una clase particular dentro de la familia de los *algoritmos evolutivos*.

El problema central que abordan puede enunciarse de manera abstracta: dado un espacio de búsqueda Ω y una función objetivo $f : \Omega \rightarrow \mathbb{R}$, encontrar (o aproximar)

$$x^* \in \arg \max_{x \in \Omega} f(x).$$

Cuando Ω es discreto, de alta dimensión, o el paisaje de f es multimodal y no diferenciable, los métodos clásicos (gradiente, programación dinámica, búsqueda exhaustiva) se vuelven inviables. Los algoritmos genéticos constituyen una alternativa robusta que opera sobre *poblaciones* de soluciones candidatas y las transforma iterativamente mediante operadores aleatorios.

Observación 1.1. A diferencia de la mayoría de los métodos de optimización, un AG no mantiene un único candidato sino una *población* de ellos. Esto proporciona paralelismo implícito y resistencia ante óptimos locales.

Observación 1.2. La analogía biológica orienta el diseño, pero el análisis matemático del algoritmo no depende de ella. Las nociones de cromosoma, gen, cruce y mutación son simplemente nombres para objetos y operaciones matemáticas precisas.

2. Representación: cromosomas y espacios de búsqueda

El primer paso en el diseño de un AG consiste en elegir una representación para las soluciones del problema.

2.1. El alfabeto y el cromosoma

Definición 2.1 (Alfabeto). Sea Σ un conjunto finito no vacío. Se denomina *alfabeto* a Σ , y a sus elementos se les llama *alelos*.

En el modelo canónico de Holland se utiliza el alfabeto binario $\Sigma = \{0, 1\}$. Otros modelos emplean $\Sigma = \{0, 1, \dots, k-1\}$ para algún entero $k \geq 2$, o incluso alfabetos reales $\Sigma \subseteq \mathbb{R}$.

Definición 2.2 (Cromosoma). Sea Σ un alfabeto y $\ell \in \mathbb{N}$ un entero positivo. Un *cromosoma* de longitud ℓ es una cadena

$$x = (x_1, x_2, \dots, x_\ell) \in \Sigma^\ell.$$

Cada posición $i \in \{1, \dots, \ell\}$ se denomina *locus*, y el valor $x_i \in \Sigma$ es el *alelo* en dicho locus.

Definición 2.3 (Espacio de búsqueda). Para un alfabeto Σ y una longitud ℓ , el *espacio de búsqueda* es

$$\Omega = \Sigma^\ell.$$

Cuando $\Sigma = \{0, 1\}$, se tiene $|\Omega| = 2^\ell$, y los cromosomas se identifican con vectores binarios de longitud ℓ .

Observación 2.4. La cardinalidad $|\Omega| = |\Sigma|^\ell$ crece exponencialmente con ℓ . En consecuencia, una búsqueda exhaustiva resulta impracticable incluso para longitudes moderadas, lo que justifica el uso de métodos heurísticos como los AG.

2.2. Genotipo, fenotipo y función de decodificación

En muchas aplicaciones, el espacio natural del problema no coincide con Σ^ℓ . Se distinguen entonces dos niveles de representación.

Definición 2.5 (Genotipo y fenotipo). Sea $\Omega_G = \Sigma^\ell$ el *espacio genotípico* y Ω_P el *espacio fenotípico*. Una *función de decodificación* es una aplicación

$$\delta : \Omega_G \rightarrow \Omega_P.$$

El cromosoma $x \in \Omega_G$ es el *genotipo* y $\delta(x) \in \Omega_P$ es su *fenotipo*.

Ejemplo 2.6 (Codificación binaria de enteros). Sea $\Omega_P = \{0, 1, \dots, 2^\ell - 1\}$. La función

$$\delta(x_1, \dots, x_\ell) = \sum_{i=1}^{\ell} x_i \cdot 2^{\ell-i}$$

convierte la representación binaria x en su valor entero correspondiente. Esta es la decodificación estándar en el modelo canónico.

Ejemplo 2.7 (Codificación Gray). La *codificación Gray* es una biyección $\gamma : \{0, 1\}^\ell \rightarrow \{0, 1\}^\ell$ tal que cromosomas adyacentes en el espacio fenotípico difieren en exactamente un bit. Formalmente, si $g = \gamma(x)$, entonces

$$g_1 = x_1, \quad g_i = x_{i-1} \oplus x_i \text{ para } i \geq 2,$$

donde $\oplus$ denota la suma módulo 2. Esta codificación evita discontinuidades en el paisaje de aptitud inducido por la representación binaria estándar.

Observación 2.8. La elección de la función de decodificación δ es una decisión de diseño crucial. Una mala representación puede dificultar la exploración efectiva del espacio y degradar el desempeño del algoritmo independientemente de los operadores elegidos.

3. Función de aptitud y paisaje de aptitud

Definición 3.1 (Función de aptitud). Sea $\Omega_G = \Sigma^\ell$ el espacio genotípico. Una *función de aptitud* es una aplicación

$$f : \Omega_G \rightarrow \mathbb{R}_{\geq 0}.$$

El valor $f(x)$ cuantifica la calidad de la solución representada por el cromosoma x . Se asume en general que valores más altos de f corresponden a soluciones preferibles.

Observación 3.2. En la práctica, la función de aptitud puede construirse como la composición de la función objetivo del problema original con la función de decodificación:

$$f = f_{\text{obj}} \circ \delta,$$

donde $f_{\text{obj}} : \Omega_P \rightarrow \mathbb{R}$ es la función que se desea maximizar.

Observación 3.3. Si el problema original es de minimización, se puede transformar la función objetivo, por ejemplo, mediante $f(x) = C - f_{\text{obj}}(\delta(x))$ para una constante C suficientemente grande, o mediante $f(x) = 1/(1 + f_{\text{obj}}(\delta(x)))$.

Definición 3.4 (Paisaje de aptitud). El *paisaje de aptitud* es la tripleta (Ω_G, d, f) , donde d es una métrica sobre Ω_G y $f : \Omega_G \rightarrow \mathbb{R}_{\geq 0}$ es la función de aptitud. La métrica más natural sobre Σ^ℓ es la *distancia de Hamming*:

$$d_H(x, y) = \sum_{i=1}^{\ell} \mathbf{1}\{x_i \neq y_i\}.$$

Observación 3.5. El concepto de paisaje de aptitud permite visualizar el problema de optimización como la búsqueda del punto más alto en una superficie definida sobre el espacio de cromosomas. La estructura topológica de este paisaje determina la dificultad del problema para el AG: paisajes rugosos (con muchos óptimos locales) son intrínsecamente más difíciles que paisajes suaves (unimodales o con pocos óptimos).

Definición 3.6 (Aptitud media y aptitud máxima de una población). Sea $P = \{x^{(1)}, \dots, x^{(\mu)}\} \subseteq \Omega_G$ una población de μ individuos. Se definen la *aptitud media* y la *aptitud máxima* como

$$\bar{f}(P) = \frac{1}{\mu} \sum_{i=1}^{\mu} f(x^{(i)}), \quad f^*(P) = \max_{1 \leq i \leq \mu} f(x^{(i)}).$$

4. Población y modelo probabilístico

Definición 4.1 (Población). Sea $\mu \in \mathbb{N}$ el *tamaño de la población*. Una *población* es un multiconjunto de cromosomas:

$$P = (x^{(1)}, x^{(2)}, \dots, x^{(\mu)}) \in \Omega_G^\mu.$$

Observación 4.2. Se utiliza un multiconjunto (secuencia) y no un conjunto, ya que pueden existir cromosomas repetidos en la población.

Definición 4.3 (Espacio de poblaciones). El *espacio de poblaciones* de tamaño μ sobre Ω_G es

$$\mathbf{P}_\mu = \Omega_G^\mu.$$

Un algoritmo genético opera como una sucesión de transformaciones aleatorias en $\mathbf{P}_\mu$.

Definición 4.4 (Inicialización aleatoria). La población inicial $P_0 = (x_0^{(1)}, \dots, x_0^{(\mu)})$ se genera de forma aleatoria. En el modelo estándar, cada locus de cada individuo se inicializa de manera independiente e idénticamente distribuida:

$$x_{0,j}^{(i)} \sim \text{Uniforme}(\Sigma), \quad i = 1, \dots, \mu, \quad j = 1, \dots, \ell.$$

Observación 4.5. La inicialización uniforme no introduce sesgo a priori hacia regiones específicas del espacio de búsqueda. Sin embargo, no garantiza una cobertura efectiva de todo Ω_G , especialmente cuando $|\Omega_G|$ es muy grande. En algunos problemas con conocimiento previo, es conveniente inicializar de forma sesgada (inicialización heurística o semi-aleatoria).

5. Operadores genéticos

El paso de una generación a la siguiente se realiza mediante tres operadores: selección, cruce y mutación. Cada uno tiene un papel bien diferenciado en la dinámica del algoritmo.

5.1. Selección

La selección es el mecanismo mediante el cual los individuos más aptos tienen mayor probabilidad de contribuir a la siguiente generación.

Definición 5.1 (Operador de selección). Un *operador de selección* es una función estocástica

$$\mathcal{S} : \mathbf{P}_\mu \rightarrow \mathbf{P}_\mu$$

que, dada una población P , produce una nueva población P' donde cada individuo $x^{(i)} \in P'$ es una copia de algún $x^{(j)} \in P$, siendo la probabilidad de seleccionar $x^{(j)}$ una función no decreciente de $f(x^{(j)})$.

Definición 5.2 (Selección proporcional (ruleta)). En la *selección proporcional a la aptitud* (también llamada selección por ruleta o *roulette-wheel selection*), la probabilidad de seleccionar el individuo $x^{(j)}$ es

$$p_j = \frac{f(x^{(j)})}{\sum_{k=1}^{\mu} f(x^{(k)})}, \quad j = 1, \dots, \mu.$$

Observación 5.3. La selección proporcional requiere que $f(x) \geq 0$ para todo x y que la aptitud total sea positiva. Un individuo con aptitud cero tiene probabilidad cero de ser seleccionado.

Observación 5.4. La selección proporcional presenta el problema de la *presión de selección prematura*: si un individuo tiene aptitud mucho mayor que los demás, tenderá a dominar la población en pocas generaciones, reduciendo la diversidad genética.

Definición 5.5 (Selección por torneo). En la *selección por torneo de tamaño k* , se eligen k individuos al azar de la población (con o sin reemplazo) y se selecciona el de mayor aptitud. Formalmente, dado un subconjunto aleatorio $T \subseteq \{1, \dots, \mu\}$ con $|T| = k$, el índice del individuo seleccionado es

$$i^* = \arg \max_{i \in T} f(x^{(i)}).$$

Observación 5.6. La selección por torneo es independiente de la escala de la aptitud: si se reemplaza f por $\alpha f + \beta$ con $\alpha > 0$, el resultado del torneo no cambia.

Proposición 5.7. Supóngase que los individuos están ordenados de mayor a menor aptitud, sin empates, de modo que el rango $r = 1$ corresponde al mejor individuo y $r = \mu$ al peor. En la selección por torneo de tamaño k con muestreo con reemplazo, la probabilidad de seleccionar al individuo de rango r es

$$p_r = \left(\frac{\mu - r + 1}{\mu} \right)^k - \left(\frac{\mu - r}{\mu} \right)^k.$$

Si existen empates, la fórmula debe ajustarse según la regla de desempate utilizada.

Definición 5.8 (Selección por truncamiento). Sea $0 < \tau \leq 1$. En la *selección por truncamiento*, solo se seleccionan los $\lfloor \tau \mu \rfloor$ individuos con mayor aptitud, de entre los cuales se forma la siguiente generación mediante muestreo uniforme.

Definición 5.9 (Selección por rango). En la *selección por rango*, los individuos se ordenan según su aptitud $f(x^{(\sigma(1))}) \leq \dots \leq f(x^{(\sigma(\mu))})$, y la probabilidad de selección del individuo de rango r es

$$p_r = \frac{w(r)}{\sum_{s=1}^{\mu} w(s)},$$

donde $w : \{1, \dots, \mu\} \rightarrow \mathbb{R}_{>0}$ es una función de peso estrictamente creciente. Una elección común es $w(r) = r$ (rango lineal).

Observación 5.10. La selección por rango evita la presión de selección prematura, ya que las probabilidades dependen solo del orden relativo de las aptitudes y no de sus valores absolutos.

5.2. Cruce (recombinación)

El cruce es el operador principal de exploración del espacio de búsqueda. Combina el material genético de dos (o más) padres para producir descendientes.

Definición 5.11 (Operador de cruce). Un *operador de cruce* (o recombinación) de aridad $\rho \geq 2$ es una función estocástica

$$\mathcal{C} : \Omega_G^\rho \rightarrow \Omega_G^\rho$$

que, dados ρ cromosomas padres $(p^{(1)}, \dots, p^{(\rho)})$, produce ρ descendientes $(h^{(1)}, \dots, h^{(\rho)})$ tales que $h_j^{(i)} \in \{p_j^{(1)}, \dots, p_j^{(\rho)}\}$ para todo $j \in \{1, \dots, \ell\}$.

Observación 5.12. La condición $h_j^{(i)} \in \{p_j^{(1)}, \dots, p_j^{(\rho)}\}$ garantiza que el cruce no introduce alelos nuevos, sino que recombina el material genético existente. La introducción de material nuevo es responsabilidad del operador de mutación.

Definición 5.13 (Cruce de un punto). El *cruce de un punto* actúa sobre dos padres $p^{(1)}, p^{(2)} \in \Sigma^\ell$. Se selecciona uniformemente un punto de corte $c \in \{1, \dots, \ell - 1\}$ y se producen dos descendientes:

$$\begin{aligned} h^{(1)} &= (p_1^{(1)}, \dots, p_c^{(1)}, p_{c+1}^{(2)}, \dots, p_\ell^{(2)}), \\ h^{(2)} &= (p_1^{(2)}, \dots, p_c^{(2)}, p_{c+1}^{(1)}, \dots, p_\ell^{(1)}). \end{aligned}$$

Definición 5.14 (Cruce de dos puntos). El *cruce de dos puntos* generaliza el anterior. Se seleccionan dos puntos de corte $1 \leq c_1 < c_2 \leq \ell - 1$ y se producen dos descendientes intercambiando el segmento central:

$$\begin{aligned} h^{(1)} &= (p_1^{(1)}, \dots, p_{c_1}^{(1)}, p_{c_1+1}^{(2)}, \dots, p_{c_2}^{(2)}, p_{c_2+1}^{(1)}, \dots, p_\ell^{(1)}), \\ h^{(2)} &= (p_1^{(2)}, \dots, p_{c_1}^{(2)}, p_{c_1+1}^{(1)}, \dots, p_{c_2}^{(1)}, p_{c_2+1}^{(2)}, \dots, p_\ell^{(2)}). \end{aligned}$$

Definición 5.15 (Cruce uniforme). En el *cruce uniforme*, cada locus $j \in \{1, \dots, \ell\}$ del primer descendiente se asigna de forma independiente:

$$h_j^{(1)} = \begin{cases} p_j^{(1)} & \text{con probabilidad } \frac{1}{2}, \\ p_j^{(2)} & \text{con probabilidad } \frac{1}{2}. \end{cases}$$

El segundo descendiente recibe, en cada locus, el alelo del padre que no fue asignado al primer descendiente:

$$h_j^{(2)} = \begin{cases} p_j^{(2)}, & \text{si } h_j^{(1)} = p_j^{(1)}, \\ p_j^{(1)}, & \text{si } h_j^{(1)} = p_j^{(2)}. \end{cases}$$

Observación 5.16. El cruce uniforme rompe la correlación entre loci vecinos que sí preservan los cruces de uno o dos puntos. En consecuencia, es más adecuado cuando los bloques constructores relevantes no son contiguos.

Definición 5.17 (Punto de corte y orden de disrupción). Sea H un conjunto de loci (véase la Sección 7). El *orden de disrupción* del cruce de un punto sobre H es la probabilidad de que el punto de corte separe algún par de loci en H :

$$P_{\text{dis}}(H) = \frac{\delta(H)}{\ell - 1},$$

donde $\delta(H) = \text{máx}(H) - \text{mín}(H)$ es la *longitud definidora* del conjunto H .

5.3. Mutación

La mutación introduce variaciones aleatorias en los cromosomas, garantizando que el algoritmo pueda explorar regiones del espacio no alcanzables mediante cruce.

Definición 5.18 (Operador de mutación). Un *operador de mutación* es una función estocástica

$$\mathcal{M} : \Omega_G \rightarrow \Omega_G$$

que, dado un cromosoma x , produce un cromosoma x' modificando aleatoriamente uno o más de sus loci.

Definición 5.19 (Mutación bit a bit (binaria)). Sea $p_m \in [0, 1]$ la *tasa de mutación*. En la *mutación bit a bit* sobre $\Sigma = \{0, 1\}$, cada locus se invierte de forma independiente:

$$x'_j = \begin{cases} 1 - x_j & \text{con probabilidad } p_m, \\ x_j & \text{con probabilidad } 1 - p_m, \end{cases} \quad j = 1, \dots, \ell.$$

Observación 5.20. Una regla empírica frecuente en representaciones binarias es tomar $p_m = 1/\ell$, de modo que en media se modifica un único locus por cromosoma en cada aplicación del operador.

Proposición 5.21 (Probabilidad de mutación exacta). *Bajo la mutación bit a bit con tasa p_m , la probabilidad de que exactamente k loci sean mutados es*

$$\mathbb{P}(d_H(x, x') = k) = \binom{\ell}{k} p_m^k (1 - p_m)^{\ell - k}.$$

En particular, la probabilidad de que el cromosoma no se modifique es $(1 - p_m)^\ell$.

Demostración. Cada locus se muta de forma independiente con probabilidad p_m . El número de loci mutados sigue una distribución Binomial(ℓ, p_m), de donde se sigue la fórmula. $\square$

Definición 5.22 (Mutación gaussiana (representación real)). Cuando $\Sigma \subseteq \mathbb{R}$ y los cromosomas son vectores reales $x \in \mathbb{R}^\ell$, la *mutación gaussiana* es

$$x'_j = x_j + \mathcal{N}(0, \sigma^2), \quad j = 1, \dots, \ell,$$

donde $\sigma > 0$ es el *tamaño de paso* y las perturbaciones son independientes.

Observación 5.23. En representaciones reales, el parámetro σ controla la magnitud de las perturbaciones. Valores grandes favorecen la exploración global; valores pequeños refinan soluciones localmente. Las estrategias de evolución adaptan σ automáticamente durante la ejecución.

6. El algoritmo genético canónico

Algoritmo 6.1 (Algoritmo Genético Canónico (AGC)). Fijos los parámetros: tamaño de población μ , tasa de cruce $p_c \in [0, 1]$, tasa de mutación $p_m \in [0, 1]$, y criterio de parada.

Paso 1. Inicialización. Generar aleatoriamente $P_0 = (x_0^{(1)}, \dots, x_0^{(\mu)})$. Fijar $t \leftarrow 0$.

Paso 2. Evaluación. Calcular $f(x_t^{(i)})$ para $i = 1, \dots, \mu$.

Paso 3. Condición de parada. Si se satisface el criterio de terminación, devolver $x^* = \arg \max_i f(x_t^{(i)})$.

Paso 4. Selección. Aplicar el operador de selección $\mathcal{S}$ para obtener una población intermedia P'_t de μ individuos.

Paso 5. Cruce. Para cada par consecutivo de individuos $(x', x'') \in P'_t$, con probabilidad p_c aplicar el operador de cruce $\mathcal{C}$ y reemplazar el par por los descendientes.

Paso 6. Mutación. Aplicar el operador de mutación $\mathcal{M}$ a cada individuo de la población resultante.

Paso 7. Actualización. Hacer P_{t+1} igual a la población resultante; $t \leftarrow t + 1$. Ir al Paso 2.

Observación 6.2. El AGC define una cadena de Markov en el espacio de poblaciones $\mathbf{P}_\mu = \Omega_G^\mu$. En efecto, la distribución de P_{t+1} depende únicamente de P_t , sin depender del historial $P_0, \dots, P_{t-1}$.

Observación 6.3 (Elitismo). En su versión básica, el AGC no garantiza la preservación del mejor individuo encontrado. Para remediar esto, se introduce el *elitismo*: los $e \geq 1$ mejores individuos de P_t se copian directamente a P_{t+1} antes de aplicar los operadores genéticos. El elitismo garantiza que $f^*(P_{t+1}) \geq f^*(P_t)$ para todo t .

Definición 6.4 (Modelo generacional y modelo estacionario). En el *modelo generacional*, todos los individuos de la generación actual son reemplazados en cada iteración (posiblemente con elitismo). En el *modelo estacionario* (steady-state), en cada iteración solo uno o dos individuos son reemplazados, manteniendo el resto de la población.

7. Esquemas: subestructuras y bloques constructores

La teoría de los esquemas, desarrollada por Holland (1975), es el marco analítico fundamental para comprender el comportamiento del algoritmo genético canónico.

7.1. Definición y propiedades de los esquemas

Definición 7.1 (Alfabeto extendido y esquema). Sea Σ el alfabeto genotípico y $\hat{\Sigma} = \Sigma \cup \{\#\}$, donde $\#$ es un símbolo especial denominado *comodín* (*wildcard*). Un *esquema* de longitud ℓ es una cadena

$$H = (H_1, H_2, \dots, H_\ell) \in \hat{\Sigma}^\ell.$$

Se dice que un cromosoma $x \in \Sigma^\ell$ *concuerta* con el esquema H , y se escribe $x \in H$, si

$$x_j = H_j \quad \text{para todo } j \text{ tal que } H_j \neq \#.$$

Ejemplo 7.2. Consideremos $\Sigma = \{0, 1\}$ y $\ell = 6$. El esquema $H = 1\#\#0\#1$ corresponde al conjunto de cromosomas

$$\{100001, 100011, 101001, 101011, 110001, 110011, 111001, 111011\}.$$

Nótese que $|H| = 2^3 = 8$, ya que hay tres comodines.

Definición 7.3 (Orden de un esquema). El *orden* del esquema H , denotado $o(H)$, es el número de posiciones con valor fijo (no comodín):

$$o(H) = |\{j \in \{1, \dots, \ell\} : H_j \neq \#\}|.$$

Definición 7.4 (Longitud definidora). La *longitud definidora* del esquema H , denotada $\delta(H)$, es la distancia entre el primer y el último locus de valor fijo:

$$\delta(H) = \max\{j : H_j \neq \#\} - \min\{j : H_j \neq \#\}.$$

Por convención, $\delta(H) = 0$ si $o(H) \leq 1$.

Observación 7.5. El número total de esquemas de longitud ℓ sobre el alfabeto binario es 3^ℓ , ya que cada posición puede tomar los valores 0, 1 o $\#$.

Observación 7.6. Un cromosoma de longitud ℓ es un miembro de exactamente 2^ℓ esquemas distintos, uno por cada subconjunto de posiciones que pueden tornarse comodines.

Definición 7.7 (Aptitud media de un esquema). La *aptitud media* del esquema H en la generación t , denotada $\bar{f}(H, t)$, es el promedio de las aptitudes de los individuos de la población que concuerdan con H :

$$\bar{f}(H, t) = \frac{1}{m(H, t)} \sum_{\substack{i=1 \\ x_t^{(i)} \in H}}^{\mu} f(x_t^{(i)}),$$

donde $m(H, t) = |\{i : x_t^{(i)} \in H\}|$ es el número de individuos en H en la generación t .

7.2. El Teorema de los Esquemas

El Teorema de los Esquemas describe cómo evoluciona el número esperado de representantes de un esquema de una generación a la siguiente.

Teorema 7.8 (Holland, 1975 — Teorema de los Esquemas). *Sea H un esquema, $m(H, t)$ el número de individuos que concuerdan con H en la generación t , y $\bar{f}(P_t)$ la aptitud media de la población en t . Bajo el AGC con selección proporcional, cruce de un punto con tasa p_c y mutación bit a bit con tasa p_m , el número esperado de representantes de H en la siguiente generación satisface:*

$$\mathbb{E}[m(H, t+1)] \geq m(H, t) \cdot \frac{\bar{f}(H, t)}{\bar{f}(P_t)} \cdot \left(1 - p_c \cdot \frac{\delta(H)}{\ell - 1}\right) \cdot (1 - p_m)^{o(H)}.$$

Demostración. La demostración analiza el efecto de cada operador por separado.

Efecto de la selección. Bajo selección proporcional, la probabilidad de seleccionar un individuo específico $x^{(i)} \in H$ es $f(x^{(i)})/(\mu \bar{f}(P_t))$. Por linealidad de la esperanza:

$$\mathbb{E}[m(H, t+1/\text{sel})] = \mu \sum_{\substack{i=1 \\ x_t^{(i)} \in H}}^{\mu} \frac{f(x^{(i)})}{\mu \bar{f}(P_t)} = m(H, t) \cdot \frac{\bar{f}(H, t)}{\bar{f}(P_t)}.$$

Efecto del cruce. El cruce de un punto destruye el esquema H únicamente cuando el punto de corte cae dentro de la longitud definidora $\delta(H)$. La probabilidad de que esto ocurra, condicionada a que se aplica el cruce (probabilidad p_c), es a lo sumo $\delta(H)/(\ell - 1)$. Por lo tanto, la probabilidad de supervivencia del esquema es al menos

$$1 - p_c \cdot \frac{\delta(H)}{\ell - 1}.$$

Efecto de la mutación. El esquema H requiere que los $o(H)$ loci definidos conserven su valor. Cada uno sobrevive a la mutación con probabilidad $1 - p_m$. Por independencia:

$$\mathbb{P}(H \text{ sobrevive mutación}) = (1 - p_m)^{o(H)}.$$

Combinando los tres efectos (la desigualdad surge porque el cruce puede *no* destruir el esquema incluso cuando el punto de corte cae en $\delta(H)$, si ambos padres concuerdan en H):

$$\mathbb{E}[m(H, t+1)] \geq m(H, t) \cdot \frac{\bar{f}(H, t)}{\bar{f}(P_t)} \cdot \left(1 - p_c \frac{\delta(H)}{\ell - 1}\right) \cdot (1 - p_m)^{o(H)}. \quad \square$$

Observación 7.9 (Interpretación del teorema). El Teorema 7.8 sugiere que, bajo condiciones favorables, los esquemas con:

- aptitud media *por encima* de la media de la población ($\bar{f}(H, t) > \bar{f}(P_t)$),
- longitud definidora *corta* ($\delta(H)$ pequeño), y
- orden *bajo* ($o(H)$ pequeño),

tienden a incrementar su representación esperada mientras su aptitud relativa se mantenga por encima de la media y la disrupción por cruce y mutación sea pequeña. Estos esquemas se denominan *bloques constructores* (*building blocks*).

Corolario 7.10. Si, durante n generaciones, la aptitud relativa del esquema se mantiene aproximadamente constante, $\bar{f}(H, s) \approx (1 + \varepsilon)\bar{f}(P_s)$ para $s = t, \dots, t + n - 1$, y si $p_c\delta(H)/(\ell - 1)$ y $p_m o(H)$ son suficientemente pequeños, entonces

$$\mathbb{E}[m(H, t + n)] \approx m(H, t) \cdot (1 + \varepsilon)^n.$$

En este régimen idealizado, el número esperado de representantes del esquema crece aproximadamente de forma exponencial.

Observación 7.11 (Limitaciones del teorema). El Teorema de los Esquemas es una cota inferior, no una ecuación exacta. Además:

1. Asume selección proporcional, que puede variar si se usan otros métodos.
2. Los esquemas no son independientes: un individuo pertenece a 2^ℓ esquemas simultáneamente, creando interacciones complejas.
3. La cota puede ser pesimista: no considera el caso en que el cruce *reconstruye* un esquema destruido.
4. El comportamiento a largo plazo de la distribución de esquemas no se captura completamente con esta cota.

7.3. Paralelismo implícito

Observación 7.12 (Paralelismo implícito). La noción clásica de *paralelismo implícito*, atribuida a Holland, sostiene que una población de μ individuos proporciona información simultánea sobre múltiples esquemas. Esta idea debe entenderse como una interpretación heurística del efecto poblacional del AG, no como una garantía exacta de procesamiento independiente de esquemas.

8. Hipótesis de los bloques constructores

Definición 8.1 (Bloque constructor). Un *bloque constructor* (*building block*) es un esquema H de orden bajo, longitud definidora corta y aptitud media alta. Formalmente, se habla de bloques constructores cuando $o(H)$ y $\delta(H)$ son pequeños relativos a ℓ , y $\bar{f}(H, t) > \bar{f}(P_t)$.

Definición 8.2 (Hipótesis de los bloques constructores (HBC)). La *Hipótesis de los Bloques Constructores* (Holland, 1975; Goldberg, 1989) afirma que el algoritmo genético resuelve eficientemente un problema al:

1. identificar bloques constructores de alta aptitud;
2. combinarlos mediante cruce para formar soluciones más complejas; y
3. propagar progresivamente estos bloques hacia la solución óptima.

Observación 8.3. La HBC es una hipótesis heurística y no un teorema. Su validez depende crucialmente de la estructura del problema: en problemas donde los bloques constructores son engañosos (es decir, donde la combinación de buenos bloques locales no conduce a buenas soluciones globales), el AG puede fallar sistemáticamente.

Definición 8.4 (Problema engañoso (deceptive problem)). Un problema de optimización se denomina *engañoso* (*deceptive*) si los bloques constructores de alta aptitud, al combinarse, llevan al AG hacia regiones del espacio distintas del óptimo global.

Ejemplo 8.5 (Trampa de orden k). La *función trampa de orden k* es un ejemplo clásico de problema engañoso. Para cromosomas binarios de longitud k , se define como

$$f_{\text{trap}}(x) = \begin{cases} k + 1 & \text{si } \sum_{j=1}^k x_j = k, \\ k - 1 - \sum_{j=1}^k x_j & \text{en otro caso.} \end{cases}$$

En esta función, el óptimo global es la cadena $\mathbf{1} = (1, \dots, 1)$ con aptitud $k + 1$, pero los esquemas parciales con $\sum x_j < k$ ceros tienen mayor aptitud media que los correspondientes con unos, lo que guía al AG hacia $\mathbf{0} = (0, \dots, 0)$.

9. Análisis de convergencia

9.1. El AG como cadena de Markov

Definición 9.1 (Cadena de Markov del AG). Sea $\mathbf{P}_\mu = \Omega_G^\mu$ el espacio de poblaciones. La sucesión $(P_t)_{t \geq 0}$ generada por el AGC es una *cadena de Markov homogénea* en $\mathbf{P}_\mu$ con espacio de estados finito $|\mathbf{P}_\mu| = |\Sigma|^{\mu\ell}$.

Observación 9.2. El espacio de estados $\mathbf{P}_\mu$ es finito, por lo que la cadena posee medidas estacionarias. Sin embargo, la cadena no es necesariamente irreducible ni aperiódica en general, lo que dificulta el análisis de convergencia.

Definición 9.3 (Estado absorbente). Se dice que una población $P \in \mathbf{P}_\mu$ es un *estado absorbente* del AGC si $P_{t+1} = P$ con probabilidad 1 cuando $P_t = P$. En el AGC sin elitismo, una población de cromosomas idénticos es absorbente si la tasa de mutación es cero.

Teorema 9.4 (Convergencia asintótica con elitismo). Sea Ω_G finito. Supóngase que el AG conserva siempre el mejor individuo encontrado hasta el momento y que, desde cualquier población, existe probabilidad positiva de generar cualquier cromosoma mediante los operadores de variación. Entonces

$$\mathbb{P} \left(\max_{0 \leq s \leq t} f^*(P_s) = \max_{x \in \Omega_G} f(x) \right) \xrightarrow{t \rightarrow \infty} 1.$$

Observación 9.5. La condición de accesibilidad requiere que la variación genética pueda generar cualquier cromosoma con probabilidad positiva, lo que normalmente se cumple con una mutación bit a bit con $p_m \in (0, 1)$. Esta condición no implica que todas las transiciones entre poblaciones sean positivas, pues el elitismo impide transiciones que pierdan el mejor individuo preservado.

Observación 9.6. El Teorema 9.4 garantiza descubrimiento asintótico del óptimo global en términos del mejor individuo encontrado, pero no garantiza una velocidad de convergencia eficiente ni que la distribución completa de la población se concentre rápidamente en una única población óptima.

9.2. Pérdida de diversidad y convergencia prematura

Definición 9.7 (Convergencia prematura). Se habla de *convergencia prematura* cuando la población pierde diversidad genética antes de alcanzar el óptimo global, quedando atrapada en un óptimo local. Formalmente, ocurre cuando $f^*(P_t) < \max_x f(x)$ pero P_t es prácticamente un estado absorbente (todos los individuos son casi idénticos).

Definición 9.8 (Diversidad genotípica). La *diversidad genotípica* de una población $P = (x^{(1)}, \dots, x^{(\mu)})$ puede cuantificarse mediante la *entropía de Shannon* por locus:

$$D(P) = \frac{1}{\ell} \sum_{j=1}^{\ell} \left(- \sum_{a \in \Sigma} \hat{p}_{j,a} \log \hat{p}_{j,a} \right),$$

donde $\hat{p}_{j,a} = \frac{1}{\mu} |\{i : x_j^{(i)} = a\}|$ es la frecuencia del alelo a en el locus j .

Observación 9.9. Cuando todos los individuos son idénticos, $D(P) = 0$. La diversidad máxima se alcanza cuando todos los alelos son equiprobables en cada locus.

9.3. No Free Lunch

Teorema 9.10 (No Free Lunch para optimización, Wolpert & Macready, 1997). *Bajo las hipótesis clásicas del teorema, si se promedia uniformemente el rendimiento sobre todas las posibles funciones objetivo, entonces cualquier par de algoritmos de optimización A_1 y A_2 tiene el mismo rendimiento esperado:*

$$\mathbb{E}_f[R(A_1, f)] = \mathbb{E}_f[R(A_2, f)],$$

donde $R(A, f)$ denota una medida de rendimiento del algoritmo A sobre la función objetivo f .

Observación 9.11. El Teorema No Free Lunch implica que no existe un algoritmo universalmente superior. Los algoritmos genéticos son eficientes solo en ciertas clases de problemas. La clave está en la adecuada codificación y en la estructura del problema, que debe ser compatible con la dinámica de los bloques constructores.

10. Dinámica poblacional y modelos continuos

Para estudiar la dinámica del AG de forma analítica, es útil introducir un modelo continuo que aproxime el comportamiento de poblaciones grandes.

Definición 10.1 (Vector de frecuencias de alelos). Sea $\Sigma = \{0, 1\}$. El *vector de frecuencias* en la generación t es

$$p^{(t)} = (p_1^{(t)}, \dots, p_\ell^{(t)}) \in [0, 1]^\ell,$$

donde $p_j^{(t)} = \frac{1}{\mu} |\{i : x_{t,j}^{(i)} = 1\}|$ es la frecuencia del alelo 1 en el locus j .

Observación 10.2. En el límite $\mu \rightarrow \infty$, la evolución de $p^{(t)}$ puede describirse mediante ecuaciones deterministas, conocidas como *ecuaciones de la dinámica de selección*. Para selección proporcional sin cruce ni mutación, se tiene

$$p_j^{(t+1)} = \frac{1}{\bar{f}^{(t)}} \sum_{x \in \Sigma^\ell} x_j f(x) \prod_{k=1}^{\ell} (p_k^{(t)})^{x_k} (1 - p_k^{(t)})^{1-x_k}.$$

Definición 10.3 (Equilibrio poblacional). Un vector de frecuencias $p^* \in [0, 1]^\ell$ es un *equilibrio* de la dinámica de selección si $p^{(t+1)} = p^{(t)} = p^*$. Los equilibrios triviales son $p^* = \mathbf{0}$ y $p^* = \mathbf{1}$, correspondientes a poblaciones convergidas a $\mathbf{0}$ y $\mathbf{1}$ respectivamente.

11. Extensiones y variantes del modelo canónico

11.1. Estrategias evolutivas $(\mu + \lambda)$ y (μ, λ)

Definición 11.1 (Estrategia $(\mu + \lambda)$). En la estrategia $(\mu + \lambda)$, a partir de una población de μ padres se generan λ descendientes. La siguiente generación está formada por los μ mejores individuos entre padres e hijos:

$$P_{t+1} = \text{top}_\mu(P_t \cup \mathcal{O}(P_t)),$$

donde $\mathcal{O}(P_t)$ denota los λ descendientes.

Definición 11.2 (Estrategia (μ, λ)). En la estrategia (μ, λ) con $\lambda \geq \mu$, los μ padres son *descartados* y la siguiente generación se forma con los mejores μ de los λ descendientes:

$$P_{t+1} = \text{top}_\mu(\mathcal{O}(P_t)).$$

Observación 11.3. La estrategia $(\mu + \lambda)$ es elitista por construcción, garantizando que $f^*(P_{t+1}) \geq f^*(P_t)$. La estrategia (μ, λ) no es elitista, lo que le confiere mayor capacidad de escapar de óptimos locales.

11.2. Algoritmos genéticos para optimización multiobjetivo

Definición 11.4 (Optimización multiobjetivo). Sea $m \geq 2$. Un *problema de optimización multiobjetivo* consiste en maximizar simultáneamente m funciones de aptitud $f_1, \dots, f_m : \Omega_G \rightarrow \mathbb{R}$.

Definición 11.5 (Dominancia de Pareto). Un cromosoma x *domina* a y (notación $x \succ y$) si

$$f_k(x) \geq f_k(y) \quad \forall k \in \{1, \dots, m\} \quad \text{y} \quad \exists k : f_k(x) > f_k(y).$$

Un individuo x^* es *Pareto-óptimo* si no existe $y \in \Omega_G$ tal que $y \succ x^*$. El conjunto de todos los individuos Pareto-óptimos es el *frente de Pareto*.

Observación 11.6. Los algoritmos genéticos multiobjetivo, como NSGA-II (Non-dominated Sorting Genetic Algorithm II) y SPEA2, mantienen una aproximación al frente de Pareto durante la evolución. Estos algoritmos utilizan la relación de dominancia para definir el operador de selección, favoreciendo a los individuos no dominados y distribuyendo la población a lo largo del frente.

11.3. Algoritmos de estimación de distribuciones (EDA)

Definición 11.7 (Algoritmo de estimación de distribuciones). Un *Estimation of Distribution Algorithm* (EDA) reemplaza los operadores de cruce y mutación por un modelo probabilístico explícito $\mathcal{M}_t$ sobre Ω_G . El algoritmo opera como sigue:

1. Seleccionar los mejores $\mu' < \mu$ individuos de P_t .

2. Ajustar el modelo: $\mathcal{M}_t \leftarrow \text{Estimar}(P_t^{\text{sel}})$.
3. Muestrear μ nuevos individuos: $P_{t+1} \sim \mathcal{M}_t$.

Ejemplo 11.8 (UMDA). El *Univariate Marginal Distribution Algorithm* (UMDA) modela cada locus de manera independiente. El modelo es un producto de Bernoullis:

$$\mathcal{M}_t(x) = \prod_{j=1}^{\ell} (p_{t,j})^{x_j} (1 - p_{t,j})^{1-x_j},$$

donde $p_{t,j}$ es la frecuencia del alelo 1 en el locus j entre los individuos seleccionados.

Observación 11.9. Los EDA evitan la disrupción de bloques constructores que puede causar el cruce, ya que el modelo probabilístico puede capturar correlaciones entre loci. Sin embargo, estimar modelos de alta complejidad (como redes bayesianas) tiene un costo computacional elevado.

11.4. AG multimodales y niching (compartición de aptitud)

En muchos problemas de optimización, la función de aptitud posee múltiples óptimos locales de interés. El AG canónico, bajo la presión de la selección, tiende a concentrar la población alrededor de un único óptimo (el global o uno destacado), perdiendo información sobre el resto de la estructura del paisaje. El objetivo de los métodos de *niching* es contrarrestar esta tendencia y mantener una población *estable y distribuida* sobre varios óptimos simultáneamente.

Optimización multimodal

Definición 11.10 (Función de aptitud multimodal). Sea $f : \Omega_G \rightarrow \mathbb{R}_{\geq 0}$ la función de aptitud. Se dice que f es *multimodal* si posee al menos dos óptimos locales distintos $x_1^*, x_2^* \in \Omega_G$ con $x_1^* \neq x_2^*$. Se dice que x^* es un *óptimo local* bajo la distancia de Hamming si

$$f(x^*) \geq f(y) \quad \text{para todo } y \in \Omega_G \text{ con } d_H(x^*, y) = 1.$$

Definición 11.11 (Cuenca de atracción). Sea x_k^* un óptimo local de f . Fijada una regla determinista de búsqueda local $\mathcal{G}$, por ejemplo una búsqueda greedy con una regla de desempate preestablecida, la *cuenca de atracción* de x_k^* es el conjunto

$$B_k = \{x \in \Omega_G : \mathcal{G}(x) \text{ converge a } x_k^*\}.$$

Bajo la hipótesis de que toda trayectoria de $\mathcal{G}$ converge a un único óptimo local, la familia $\{B_k\}_{k=1}^K$ induce una partición de Ω_G en K cuencas.

Observación 11.12. La hipótesis anterior evita ambigüedades debidas a empates o a reglas de búsqueda local no especificadas. En la práctica, las cuencas de atracción deben entenderse como regiones del espacio desde las cuales una búsqueda local tendería a converger hacia el mismo óptimo.

Observación 11.13. El objetivo de la optimización multimodal no es necesariamente encontrar todos los óptimos locales existentes, sino localizar varios óptimos relevantes, suficientemente separados y de alta aptitud. Esto es de interés cuando las soluciones subóptimas también son válidas, o cuando se busca robustez ante perturbaciones en la función objetivo.

Nichos y compartición de aptitud

Definición 11.14 (Función de compartición). Sea $\sigma_{\text{sh}} > 0$ un parámetro denominado *radio de nicho* y $\alpha \geq 1$. La *función de compartición* es la aplicación $\text{sh} : \mathbb{R}_{\geq 0} \rightarrow [0, 1]$ definida por

$$\text{sh}(d) = \begin{cases} 1 - \left(\frac{d}{\sigma_{\text{sh}}}\right)^\alpha & \text{si } d < \sigma_{\text{sh}}, \\ 0 & \text{si } d \geq \sigma_{\text{sh}}. \end{cases}$$

Observación 11.15. La función de compartición cuantifica la similitud entre dos individuos: vale 1 cuando $d = 0$ (individuos idénticos) y decrece a 0 cuando la distancia se aproxima al radio de nicho σ_{sh} . El parámetro α controla la forma de la curva; el caso $\alpha = 1$ produce una forma lineal.

Definición 11.16 (Conteo de nicho). Dada una población $P = (x^{(1)}, \dots, x^{(\mu)})$ y un individuo $x^{(i)} \in P$, el *conteo de nicho* de $x^{(i)}$ es

$$m(x^{(i)}, P) = \sum_{j=1}^{\mu} \text{sh}(d(x^{(i)}, x^{(j)})).$$

Observación 11.17. Por construcción, $m(x^{(i)}, P) \geq \text{sh}(0) = 1$, pues el propio individuo contribuye con 1 a su conteo. Un individuo aislado, sin vecinos en su radio de nicho, tiene $m \approx 1$; uno rodeado de individuos similares tiene $m > 1$, y puede tener $m \gg 1$ si la región está densamente poblada.

Definición 11.18 (Aptitud compartida). La *aptitud compartida* (*shared fitness*) del individuo $x^{(i)}$ en la población P es

$$f'(x^{(i)}, P) = \frac{f(x^{(i)})}{m(x^{(i)}, P)}.$$

El AG con compartición de aptitud reemplaza f por $f'(\cdot, P_t)$ en el operador de selección en cada generación t .

Observación 11.19 (Interpretación económica). La aptitud compartida puede interpretarse como la *aptitud per cápita* dentro del nicho. Si varios individuos compiten por los mismos recursos en una región del espacio, la aptitud efectiva de cada uno disminuye proporcionalmente al número ponderado de competidores cercanos. Esto introduce una *presión de repulsión* entre individuos similares.

Modelo de repulsión estocástica

Para analizar el efecto de la compartición de aptitud sobre la dinámica poblacional, es útil reformularla como un mecanismo de repulsión dependiente de la densidad local.

Definición 11.20 (Potencial de repulsión). Dados dos individuos $x, y \in \Omega_G$, definimos el *potencial de repulsión* inducido por la función de compartición como

$$V(x, y) = \log(1 + \text{sh}(d(x, y))) \geq 0.$$

Definición 11.21 (Energía de interacción de la población). Dada una población $P = (x^{(1)}, \dots, x^{(\mu)})$, la *energía de interacción* es la función

$$U(P) = \sum_{i \neq j} \log(1 + \text{sh}(d(x^{(i)}, x^{(j)}))) .$$

La suma anterior cuenta interacciones ordenadas. Si se desea contar cada par una sola vez, puede usarse el factor $\frac{1}{2}U(P)$.

Proposición 11.22 (Relación entre aptitud compartida y energía). *La aptitud compartida satisface la identidad*

$$\log f'(x^{(i)}, P) = \log f(x^{(i)}) - \log \left(1 + \sum_{j \neq i} \text{sh}(d(x^{(i)}, x^{(j)})) \right) .$$

Además, si las contribuciones individuales $\text{sh}(d(x^{(i)}, x^{(j)}))$ son pequeñas, entonces

$$\log f'(x^{(i)}, P) \approx \log f(x^{(i)}) - \sum_{j \neq i} V(x^{(i)}, x^{(j)}) .$$

En este régimen, maximizar f' puede interpretarse como maximizar la aptitud original penalizada por una energía de repulsión local.

Demostración. Se tiene

$$m(x^{(i)}, P) = 1 + \sum_{j \neq i} \text{sh}(d(x^{(i)}, x^{(j)})) ,$$

de modo que

$$\begin{aligned} \log f'(x^{(i)}, P) &= \log f(x^{(i)}) - \log m(x^{(i)}, P) \\ &= \log f(x^{(i)}) - \log \left(1 + \sum_{j \neq i} \text{sh}(d(x^{(i)}, x^{(j)})) \right) . \end{aligned}$$

La primera igualdad es exacta. Para obtener la aproximación, se usa $\log(1+s) = s + O(s^2)$ cuando s es pequeño. Asimismo,

$$V(x, y) = \log(1 + \text{sh}(d(x, y))) = \text{sh}(d(x, y)) + O(\text{sh}(d(x, y))^2) .$$

Por tanto, cuando las contribuciones de compartición son pequeñas,

$$\log m(x^{(i)}, P) \approx \sum_{j \neq i} \text{sh}(d(x^{(i)}, x^{(j)})) \approx \sum_{j \neq i} V(x^{(i)}, x^{(j)}) .$$

□

Observación 11.23. La Proposición 11.22 muestra que la compartición de aptitud introduce, en escala logarítmica, una penalización dependiente de la densidad local de individuos. Cuanto más poblado está un nicho, mayor es la penalización aplicada a sus miembros, desincentivando la concentración excesiva.

Distribución estacionaria y mezcla de Gibbs

El AG con compartición de aptitud define, bajo una elección fija de operadores selección–cruce–mutación, una cadena de Markov en el espacio de poblaciones $\mathbf{P}_\mu$. En general, su distribución estacionaria no tiene una forma cerrada simple. Sin embargo, bajo hipótesis de separación entre cuencas, mutación pequeña y equilibrio local, puede modelarse mediante una mezcla de distribuciones de tipo Gibbs.

Definición 11.24 (Distribución de Gibbs). Sea $\beta > 0$ un parámetro de *temperatura inversa*. La *distribución de Gibbs* sobre Ω_G con función de energía $E : \Omega_G \rightarrow \mathbb{R}$ es

$$\pi_\beta(x) = \frac{1}{Z_\beta} \exp(-\beta E(x)), \quad Z_\beta = \sum_{y \in \Omega_G} \exp(-\beta E(y)).$$

Para maximización de aptitud, se toma formalmente $E(x) = -f(x)$, de modo que

$$\pi_\beta(x) = \frac{\exp(\beta f(x))}{Z_\beta}.$$

Observación 11.25. Cuando $\beta \rightarrow 0$ (temperatura alta), π_β converge a la distribución uniforme sobre Ω_G . Cuando $\beta \rightarrow \infty$ (temperatura baja), π_β concentra su masa en el conjunto de maximizadores globales de f ; si hay varios, la masa se reparte entre ellos de acuerdo con la normalización inducida por Z_β .

Definición 11.26 (Distribución de Gibbs local). Sea x_k^* un óptimo local con cuenca de atracción B_k . La *distribución de Gibbs local* restringida a B_k es

$$\pi_\beta^{(k)}(x) = \frac{\exp(\beta f(x))}{Z_\beta^{(k)}} \mathbf{1}_{B_k}(x), \quad Z_\beta^{(k)} = \sum_{y \in B_k} \exp(\beta f(y)).$$

Definición 11.27 (Mezcla de distribuciones de Gibbs). Dados K óptimos locales con pesos $\alpha_1, \dots, \alpha_K > 0$ tales que $\sum_{k=1}^K \alpha_k = 1$, la *mezcla de distribuciones de Gibbs locales* es

$$\Pi_\beta(x) = \sum_{k=1}^K \alpha_k \pi_\beta^{(k)}(x).$$

Teorema 11.28 (Aproximación estacionaria por mezcla de Gibbs). Sea f multimodal con K óptimos locales y cuencas $B_1, \dots, B_K$. Sea π^* la distribución estacionaria marginal de un individuo bajo el AG con compartición de aptitud, suponiendo que dicha distribución estacionaria existe. Bajo las condiciones ideales:

(I) las cuencas están separadas respecto al radio de compartición, es decir,

$$\Delta_B := \min_{k \neq k'} \min_{\substack{x \in B_k \\ y \in B_{k'}}} d(x, y) \geq \sigma_{\text{sh}},$$

(II) la tasa efectiva de migración entre cuencas es pequeña en comparación con la tasa de mezcla dentro de cada cuenca,

(III) el tamaño de población es suficiente para sostener representantes en varios nichos, en particular $\mu \geq K$,

(IV) dentro de cada cuenca, la dinámica local puede aproximarse por una distribución exponencial en la aptitud con temperatura inversa efectiva $\beta_{\text{eff}} > 0$,

la distribución estacionaria marginal puede aproximarse por

$$\pi^*(x) \approx \Pi_{\beta_{\text{eff}}}(x) = \sum_{k=1}^K \alpha_k \pi_{\beta_{\text{eff}}}^{(k)}(x).$$

Los pesos α_k son los pesos estacionarios de la dinámica agregada entre cuencas. En el caso ideal de migración débil y simétrica, una aproximación común es

$$\alpha_k \propto Z_{\beta_{\text{eff}}}^{(k)}.$$

Esquema de demostración. La demostración es formal y se desarrolla en dos escalas temporales.

Etap 1: Dinámica intracuenca. Por la condición (i), si $x \in B_k$ e $y \in B_{k'}$ con $k \neq k'$, entonces $\text{sh}(d(x, y)) = 0$. Por tanto, la penalización por compartición actúa principalmente dentro de cada cuenca. La condición (ii) establece una separación de escalas: antes de que ocurran migraciones relevantes entre cuencas, la población dentro de cada B_k alcanza un equilibrio local aproximado.

Bajo la hipótesis (iv), dicho equilibrio local puede modelarse mediante una distribución de Gibbs local:

$$\mu_k(x) \approx \frac{\exp(\beta_{\text{eff}} f(x))}{Z_{\beta_{\text{eff}}}^{(k)}} \mathbf{1}_{B_k}(x) = \pi_{\beta_{\text{eff}}}^{(k)}(x).$$

El parámetro β_{eff} resume la intensidad efectiva de selección, mutación, cruce y reemplazo dentro de la cuenca.

Etap 2: Dinámica intercuenca. A escala lenta, las migraciones inducidas por mutación, cruce o reemplazo pueden aproximarse por una cadena de Markov agregada sobre el conjunto de cuencas $\{B_1, \dots, B_K\}$. Si $Q = (q_{kk'})$ denota la matriz de transición efectiva entre cuencas, los pesos de mezcla $\alpha = (\alpha_1, \dots, \alpha_K)$ satisfacen

$$\alpha Q = \alpha, \quad \sum_{k=1}^K \alpha_k = 1.$$

Por tanto, la marginal estacionaria se aproxima por una mezcla de equilibrios locales:

$$\pi^*(x) \approx \sum_{k=1}^K \alpha_k \pi_{\beta_{\text{eff}}}^{(k)}(x).$$

En el caso ideal de migración débil y aproximadamente simétrica, los pesos se aproximan por la masa local normalizante, es decir, $\alpha_k \propto Z_{\beta_{\text{eff}}}^{(k)}$. $\square$

Observación 11.29 (Interpretación del Teorema 11.28). El resultado no debe leerse como una fórmula exacta para todo AG con niching, sino como una aproximación de equilibrio bajo separación de escalas. La población se interpreta como una mezcla de subpoblaciones: cada una se concentra alrededor de un óptimo local, mientras que los pesos α_k describen la proporción estacionaria de individuos asignada a cada nicho.

Observación 11.30. El parámetro β_{eff} emerge de la interacción entre selección, cruce, mutación, reemplazo y compartición de aptitud; no coincide en general con ningún parámetro explícito del AG. Valores grandes de β_{eff} corresponden a una mayor concentración alrededor de los óptimos locales; valores pequeños corresponden a distribuciones locales más dispersas.

Análisis de estabilidad de nichos

Proposición 11.31 (Criterio suficiente de persistencia de un nicho). *Sea k un nicho con óptimo local x_k^* y aptitud $f_k^* = f(x_k^*)$. Sea m_k el conteo de nicho del representante más apto de B_k . Definamos la aptitud compartida media poblacional como*

$$\bar{f}'(P_t) = \frac{1}{\mu} \sum_{j=1}^{\mu} f'(x^{(j)}, P_t).$$

Si

$$\frac{f_k^*}{m_k} \geq \bar{f}'(P_t),$$

entonces el representante más apto del nicho k tiene aptitud compartida no inferior a la media poblacional compartida y, bajo selección proporcional a f' , no está en desventaja selectiva en esa generación.

Demostración. Bajo selección proporcional a f' , la probabilidad de seleccionar al individuo $x^{(i)}$ es

$$p_i^{\text{sel}} = \frac{f'(x^{(i)}, P_t)}{\sum_{j=1}^{\mu} f'(x^{(j)}, P_t)}.$$

El número esperado de copias de $x^{(i)}$ después de la selección proporcional es

$$\mu p_i^{\text{sel}} = \frac{f'(x^{(i)}, P_t)}{\bar{f}'(P_t)}.$$

Por tanto, si el mejor representante del nicho k satisface $f_k^*/m_k \geq \bar{f}'(P_t)$, entonces su número esperado de copias es al menos uno. Esto no garantiza por sí solo la permanencia del nicho para todo tiempo, pero sí proporciona un criterio suficiente de persistencia en esperanza para la generación considerada. $\square$

Corolario 11.32 (Capacidad aproximada de un nicho). *Bajo la aproximación de que los individuos del nicho son muy similares entre sí, de modo que el conteo de nicho es comparable al número efectivo de individuos en él, el nicho k puede sostener aproximadamente hasta*

$$m_k^{\text{máx}} \approx \frac{f_k^*}{\bar{f}'(P_t)}$$

individuos efectivos antes de que la penalización por compartición elimine su ventaja selectiva. En particular, nichos asociados a óptimos de mayor aptitud tienden a sostener más individuos.

Proposición 11.33 (Criterio de elección de σ_{sh}). *Sea*

$$\Delta_B := \min_{k \neq k'} \min_{\substack{x \in B_k \\ y \in B_{k'}}} d(x, y)$$

la distancia mínima entre cuencas distintas. Para que individuos pertenecientes a cuencas distintas no contribuyan al conteo de nicho entre sí, es suficiente y, con la función sh definida arriba, necesario que

$$\sigma_{\text{sh}} \leq \Delta_B.$$

Demostración. Por definición,

$$\text{sh}(d(x, y)) = 0 \quad \text{si y solo si} \quad d(x, y) \geq \sigma_{\text{sh}}.$$

Por tanto, para que $\text{sh}(d(x, y)) = 0$ para todo $x \in B_k$, $y \in B_{k'}$ con $k \neq k'$, se requiere y basta que

$$d(x, y) \geq \sigma_{\text{sh}} \quad \text{para todo par intercuenca.}$$

Esto equivale a

$$\Delta_B \geq \sigma_{\text{sh}}.$$

□

Observación 11.34. En la práctica, Δ_B es desconocida a priori. Si solo se conocen o se estiman las distancias entre óptimos locales,

$$d_{\text{mín}} = \min_{k \neq k'} d(x_k^*, x_{k'}^*),$$

entonces la regla

$$\sigma_{\text{sh}} \lesssim \frac{d_{\text{mín}}}{2}$$

puede usarse como heurística conservadora para evitar solapamiento entre nichos centrados en óptimos distintos. Sin embargo, esta regla no es una condición necesaria y suficiente para separar cuencas completas, pues las cuencas pueden acercarse entre sí aunque sus óptimos estén relativamente separados.

Observación 11.35. Otra heurística común, cuando se espera encontrar aproximadamente K nichos distribuidos en un espacio de búsqueda de dimensión efectiva ℓ , es tomar

$$\sigma_{\text{sh}} \approx c \left(\frac{|\Omega_G|}{K} \right)^{1/\ell},$$

donde $c > 0$ es una constante de escala. Esta regla debe interpretarse como una guía de orden de magnitud, no como una elección óptima universal.

Variantes y métodos relacionados

Definición 11.36 (Crowding determinístico). El *crowding determinístico* es una variante en la que los descendientes compiten preferentemente contra individuos similares. En una formulación usual, dados dos padres p_1, p_2 y dos descendientes h_1, h_2 , se empareja cada descendiente con el padre más similar y el reemplazo se realiza dentro de esos pares, conservando al individuo de mayor aptitud:

$$\{p_1, p_2\} \longrightarrow \{h_1, h_2\}, \quad \text{reemplazo según similitud y aptitud.}$$

De forma más general, puede implementarse reemplazando cada descendiente h por un individuo similar de la población:

$$x^{(r)} = \arg \min_{x^{(i)} \in P} d(h, x^{(i)}), \quad P \leftarrow (P \setminus \{x^{(r)}\}) \cup \{h\},$$

siempre que el criterio de reemplazo preserve o mejore la aptitud local. Este mecanismo mantiene diversidad actuando sobre el operador de reemplazo, sin modificar directamente la función de aptitud.

Definición 11.37 (Niching por restricción de apareamiento). En el *niching por restricción de apareamiento* (*mating restriction*), el cruce solo se permite entre individuos suficientemente similares. Formalmente,

$$\text{se permite el cruce entre } x^{(i)} \text{ y } x^{(j)} \implies d(x^{(i)}, x^{(j)}) < \sigma_{\text{mate}}.$$

Equivalentemente, puede imponerse la regla

$$d(x^{(i)}, x^{(j)}) \geq \sigma_{\text{mate}} \implies \text{no se permite el cruce entre } x^{(i)} \text{ y } x^{(j)}.$$

Esto ayuda a preservar la estructura de nichos al reducir la mezcla de material genético entre regiones alejadas del paisaje de aptitud.

Observación 11.38. Las distintas técnicas de niching abordan el mismo objetivo desde perspectivas complementarias:

- La *compartición de aptitud* actúa sobre la función objetivo efectiva.
- El *crowding* actúa sobre el operador de reemplazo.
- La *restricción de apareamiento* actúa sobre el operador de cruce.

En la práctica, estas estrategias pueden combinarse para mejorar la preservación de diversidad.

Referencias

1. Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
2. Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
3. Mitchell, M. (1996). *An Introduction to Genetic Algorithms*. MIT Press.
4. Wolpert, D. H., & Macready, W. G. (1997). No Free Lunch Theorems for Optimization. *IEEE Transactions on Evolutionary Computation*, 1(1), 67–82.
5. Deb, K. (2001). *Multi-Objective Optimization Using Evolutionary Algorithms*. Wiley.
6. Bäck, T. (1996). *Evolutionary Algorithms in Theory and Practice*. Oxford University Press.
7. Larrañaga, P., & Lozano, J. A. (2002). *Estimation of Distribution Algorithms*. Kluwer Academic Publishers.
8. Rechenberg, I. (1973). *Evolutionstrategie: Optimierung technischer Systeme nach Prinzipien der biologischen Evolution*. Frommann-Holzboog.