

Algoritmos Genéticos: Fundamentos y Formalización Matemática

El Algoritmo Genético Canónico como Cadena de Markov

Un Estudio Riguroso

Luis Alfredo Ramírez Maza

Junio 2025

Contents

1	Introducción y motivación	2
2	Recapitulación: espacio de estados y dinámica	2
2.1	Espacio de búsqueda y espacio de poblaciones	2
2.2	El AGC como operador estocástico	2
3	Formulación markoviana formal	3
3.1	La propiedad de Markov	3
3.2	Factorización del kernel de transición	3
4	Propiedades estructurales de la cadena	4
4.1	Irreducibilidad	4
4.2	Aperiodicidad	5
4.3	Ergodicidad y distribución estacionaria	5
5	Estados absorbentes y elitismo	6
5.1	Estados absorbentes en el AGC sin mutación	6
5.2	El AGC elitista: cadena absorbente al óptimo	6
6	Convergencia al óptimo global	7
6.1	Convergencia asintótica con elitismo y mutación	7
6.2	No convergencia del AGC ergódico sin elitismo	8
7	Análisis de la distribución estacionaria	8
7.1	Caracterización implícita de π^*	8
7.2	Relación entre π^* y la aptitud	9
8	Tasas de convergencia y mezcla	9
8.1	Tiempo de mezcla	9
8.2	El segundo valor propio y la brecha espectral	10
8.3	Relación entre tasa de mutación y mezcla	10

9	Cadenas de Markov reducidas: proyecciones y lumpability	10
9.1	Proyección sobre la aptitud máxima	11
9.2	Lumpability y particiones compatibles	11
10	Tiempo esperado de primera visita al óptimo	11
10.1	Cota superior del tiempo esperado	12
11	Comportamiento asintótico de la distribución de la aptitud	12
11.1	Concentración alrededor del óptimo con elitismo	12
11.2	Distribución asintótica de la aptitud media	12
12	Conexión con el Teorema de los Esquemas	12
13	El modelo de dos escalas temporales	13
14	Síntesis: cuadro comparativo de los regímenes del AGC	14
15	Conclusiones	14
	Referencias	15

1 Introducción y motivación

El Algoritmo Genético Canónico (AGC) genera, a partir de una población inicial $P_0 \in \mathcal{P}_\mu$, una sucesión de poblaciones $(P_t)_{t \geq 0}$ mediante la aplicación iterada de tres operadores estocásticos: selección, cruce y mutación. Una observación fundamental, mencionada en las notas originales, es que esta sucesión define una *cadena de Markov en tiempo discreto y espacio de estados finito*.

El encuadre markoviano no es meramente estético: proporciona el lenguaje preciso para formular y responder preguntas de carácter teórico que de otro modo resultarían informales:

- ¿Converge el AGC al óptimo global? ¿Con qué probabilidad y en qué sentido?
- ¿A qué distribución estacionaria, si existe, tiende la cadena?
- ¿Cómo afecta el elitismo a la irreducibilidad y aperiodicidad?
- ¿Qué rol juega la tasa de mutación en la ergodicidad del proceso?

En este documento se desarrolla de manera sistemática la teoría de cadenas de Markov aplicada al AGC, manteniendo la notación y los convenios establecidos en las notas base. Se asume familiaridad con los conceptos allí introducidos: cromosoma, población, operadores genéticos, y el Teorema de los Esquemas.

2 Recapitulación: espacio de estados y dinámica

2.1 Espacio de búsqueda y espacio de poblaciones

Recordamos la configuración básica. Se fija un alfabeto Σ (por defecto $\Sigma = \{0, 1\}$), una longitud $\ell \in \mathbb{N}$ y un tamaño de población $\mu \in \mathbb{N}$.

Definición 2.1 (Espacio genotípico y espacio de poblaciones). El *espacio genotípico* es $\Omega_G = \Sigma^\ell$, con $|\Omega_G| = |\Sigma|^\ell$. El *espacio de poblaciones* de tamaño μ es

$$\mathcal{P}_\mu = \Omega_G^\mu,$$

cuyos elementos son multiconjuntos (secuencias ordenadas) $P = (x^{(1)}, \dots, x^{(\mu)})$ de μ cromosomas. La cardinalidad del espacio de estados es

$$|\mathcal{P}_\mu| = |\Sigma|^{\mu\ell}.$$

Observación 2.2. Para $\Sigma = \{0, 1\}$, $\ell = 10$ y $\mu = 20$ ya se tiene $|\mathcal{P}_\mu| = 2^{200} \approx 1.6 \times 10^{60}$, lo que hace inviable cualquier tratamiento enumerativo directo de la cadena. El análisis debe proceder de forma estructural.

2.2 El AGC como operador estocástico

Cada iteración del AGC aplica la composición de tres operadores estocásticos:

$$\Phi = M \circ C \circ S, \tag{1}$$

donde S , C y M denotan, respectivamente, el operador de selección, cruce y mutación. Cada uno de ellos es una función medible del tipo $\Omega_G^\mu \rightarrow \Omega_G^\mu$ definida en un espacio de probabilidad adecuado.

Definición 2.3 (Kernel de transición del AGC). El *kernel de transición* del AGC es la función

$$T : \mathcal{P}_\mu \times 2^{\mathcal{P}_\mu} \longrightarrow [0, 1]$$

definida por

$$T(P, A) = \mathbb{P}(\Phi(P) \in A), \quad P \in \mathcal{P}_\mu, \quad A \subseteq \mathcal{P}_\mu.$$

Cuando $\mathcal{P}_\mu$ es finito (lo cual siempre ocurre con $|\Sigma| < \infty$ y $\ell, \mu < \infty$), el kernel se reduce a una *matriz de transición estocástica* $\mathbf{T} \in [0, 1]^{|\mathcal{P}_\mu| \times |\mathcal{P}_\mu|}$ con entradas

$$T_{P,Q} = \mathbb{P}(\Phi(P) = Q), \quad P, Q \in \mathcal{P}_\mu.$$

3 Formulación markoviana formal

3.1 La propiedad de Markov

Teorema 3.1 (El AGC es una cadena de Markov homogénea). Sea $(P_t)_{t \geq 0}$ la sucesión de poblaciones generada por el AGC con parámetros fijos μ, p_c, p_m . Entonces:

(i) **Propiedad de Markov:** Para todo $t \geq 1$ y todo $Q \in \mathcal{P}_\mu$,

$$\mathbb{P}(P_{t+1} = Q \mid P_0, P_1, \dots, P_t) = \mathbb{P}(P_{t+1} = Q \mid P_t).$$

(ii) **Homogeneidad:** La probabilidad anterior no depende de t :

$$\mathbb{P}(P_{t+1} = Q \mid P_t = P) = T_{P,Q} \quad \forall t \geq 0.$$

Proof. Los operadores S, C y M se aplican en cada generación de manera idéntica e independiente de la historia pasada: la única entrada es la población actual P_t . Formalmente, existe un espacio de probabilidad $(\Omega_\omega, \mathcal{F}, \mathbb{P})$ y variables aleatorias i.i.d. $\omega_0, \omega_1, \dots$ tales que

$$P_{t+1} = \Phi(P_t, \omega_t),$$

donde $\Phi : \mathcal{P}_\mu \times \Omega_\omega \rightarrow \mathcal{P}_\mu$ es la función determinista que implementa selección, cruce y mutación dado el conjunto de números aleatorios ω_t . Como ω_t es independiente de $P_0, \dots, P_t$, se sigue la propiedad de Markov. La homogeneidad se debe a que Φ y la distribución de ω_t no varían con t (parámetros fijos). $\square$

3.2 Factorización del kernel de transición

La estructura del AGC permite descomponer $T_{P,Q}$ en tres factores correspondientes a los tres operadores. Para $P, Q \in \mathcal{P}_\mu$ definimos las poblaciones intermedias $P' = S(P)$ (post-selección) y $P'' = C(P')$ (post-cruce), de modo que $Q = M(P'')$.

Proposición 3.2 (Factorización del kernel). El kernel de transición satisface

$$T_{P,Q} = \sum_{P' \in \mathcal{P}_\mu} \sum_{P'' \in \mathcal{P}_\mu} T_{P,P'}^S T_{P',P''}^C T_{P'',Q}^M, \quad (2)$$

donde T^S, T^C y T^M son las matrices de transición inducidas por selección, cruce y mutación, respectivamente. En notación matricial,

$$\mathbf{T} = \mathbf{T}^S \mathbf{T}^C \mathbf{T}^M.$$

Proof. Por la regla de probabilidad total aplicada a las poblaciones intermedias P' y P'' . La independencia entre los operadores (dado el estado actual) garantiza la factorización del integrando. $\square$

Kernel de selección proporcional

Bajo selección proporcional (ruleta), cada individuo de $P' = (y^{(1)}, \dots, y^{(\mu)})$ se elige i.i.d. de la distribución sobre P :

$$T_{P,P'}^S = \prod_{i=1}^{\mu} \frac{f(y^{(i)})}{\sum_{k=1}^{\mu} f(x^{(k)})}, \quad y^{(i)} \in \{x^{(1)}, \dots, x^{(\mu)}\}.$$

Kernel de cruce de un punto

Dado un par de padres $(p^{(1)}, p^{(2)})$, el cruce con probabilidad p_c produce dos descendientes eligiendo uniformemente un punto de corte $c \in \{1, \dots, \ell - 1\}$:

$$T_{(p^{(1)}, p^{(2)}), (h^{(1)}, h^{(2)})}^C = \begin{cases} \frac{p_c}{\ell - 1} & \text{si } \exists c : h^{(1)}, h^{(2)} \text{ se obtienen de } p^{(1)}, p^{(2)} \text{ con corte } c, \\ 1 - p_c & \text{si } h^{(1)} = p^{(1)}, h^{(2)} = p^{(2)}, \\ 0 & \text{en otro caso.} \end{cases}$$

Kernel de mutación bit a bit

La mutación de cada individuo es independiente. Para un único cromosoma,

$$T_{x,y}^M = p_m^{d_H(x,y)} (1 - p_m)^{\ell - d_H(x,y)}, \quad x, y \in \Omega_G,$$

donde d_H es la distancia de Hamming. El kernel de poblaciones completas es el producto sobre los μ individuos (por independencia).

4 Propiedades estructurales de la cadena

4.1 Irreducibilidad

Definición 4.1 (Irreducibilidad). Una cadena de Markov con espacio de estados $\mathcal{S}$ y matriz de transición $\mathbf{T}$ es *irreducible* si para todo par $P, Q \in \mathcal{S}$ existe $n \geq 1$ tal que $T_{P,Q}^{(n)} > 0$, donde $T^{(n)} = \mathbf{T}^n$ denota la potencia n -ésima.

Teorema 4.2 (Irreducibilidad del AGC con mutación positiva). *Sea el AGC sin elitismo con tasa de mutación $p_m \in (0, 1)$. Entonces la cadena $(P_t)_{t \geq 0}$ es irreducible sobre $\mathcal{P}_\mu$.*

Proof. Sean $P, Q \in \mathcal{P}_\mu$ cualesquiera. Se construye una trayectoria de probabilidad positiva de P a Q en un número finito de pasos.

Paso 1 (mutación alcanza cualquier cromosoma). Dado cualquier cromosoma $x \in \Omega_G$ y cualquier $y \in \Omega_G$, la mutación bit a bit satisface $T_{x,y}^M = p_m^{d_H(x,y)} (1 - p_m)^{\ell - d_H(x,y)} > 0$ pues $p_m \in (0, 1)$.

Paso 2 (alcanzabilidad en un paso). Sea $Q = (q^{(1)}, \dots, q^{(\mu)})$. Desde P , en la selección proporcional existe probabilidad positiva de producir cualquier multiconjunto de copias de los individuos de P (asumiendo $f > 0$). Luego, el cruce con probabilidad $1 - p_c > 0$ deja los individuos sin modificar. Finalmente, la mutación bit a bit transforma

cada individuo en cualquier cromosoma deseado $q^{(i)}$ con probabilidad positiva (Paso 1). Siendo los individuos independientes entre sí en la fase de mutación,

$$T_{P,Q} \geq \left[(1 - p_c)^{\mu/2} \right] \cdot \prod_{i=1}^{\mu} p_m^{d_H(x^{(i*)}, q^{(i)})} (1 - p_m)^{\ell - d_H(x^{(i*)}, q^{(i)})} > 0,$$

donde $x^{(i*)}$ es cualquier individuo seleccionado de P .

Como $T_{P,Q} > 0$ para todo par, la cadena es irreducible en un solo paso. $\square$

Observación 4.3. La condición $p_m \in (0, 1)$ es esencial. Con $p_m = 0$, una población uniforme $P = (x, x, \dots, x)$ no puede generar cromosomas distintos de x mediante cruce sin mutación, por lo que existen estados inaccesibles.

4.2 Aperiodicidad

Definición 4.4 (Período de un estado). El *período* de un estado $P \in \mathcal{P}_\mu$ es

$$d(P) = \gcd\{n \geq 1 : T_{P,P}^{(n)} > 0\}.$$

La cadena es *aperiódica* si $d(P) = 1$ para todo P .

Proposición 4.5 (Aperiodicidad del AGC). *Bajo las hipótesis del theorem 4.2, la cadena del AGC es aperiódica.*

Proof. Sea $P \in \mathcal{P}_\mu$ cualquier población. La posibilidad de que ninguna mutación ocurra (probabilidad $(1 - p_m)^\ell > 0$ por cromosoma) y de que no se aplique cruce (probabilidad $(1 - p_c)^{\mu/2} > 0$) y de que la selección replique exactamente P implica que $T_{P,P} > 0$, es decir, existe probabilidad positiva de regresar a P en exactamente un paso. Por tanto $d(P) = 1$ para todo P , y la cadena es aperiódica. $\square$

4.3 Ergodicidad y distribución estacionaria

Teorema 4.6 (Ergodicidad del AGC sin elitismo). *Sea el AGC sin elitismo con $p_m \in (0, 1)$. La cadena $(P_t)_{t \geq 0}$ es ergódica (irreducible, aperiódica y con espacio de estados finito), por lo que:*

(i) *Existe una única distribución estacionaria π^* sobre $\mathcal{P}_\mu$, que satisface*

$$\pi^* \mathbf{T} = \pi^*, \quad \sum_{P \in \mathcal{P}_\mu} \pi^*(P) = 1.$$

(ii) *Para todo estado inicial $P_0 \in \mathcal{P}_\mu$,*

$$\lim_{t \rightarrow \infty} T_{P_0, Q}^{(t)} = \pi^*(Q) \quad \forall Q \in \mathcal{P}_\mu.$$

(iii) *Vale la ley de los grandes números para la cadena: para cualquier función $g : \mathcal{P}_\mu \rightarrow \mathbb{R}$,*

$$\frac{1}{n} \sum_{t=0}^{n-1} g(P_t) \xrightarrow{n \rightarrow \infty} \sum_{P \in \mathcal{P}_\mu} \pi^*(P) g(P) \quad c.s.$$

Proof. Los puntos (i) y (ii) son consecuencia directa del Teorema Fundamental de las Cadenas de Markov finitas: toda cadena irreducible y aperiódica sobre un espacio finito es ergódica. La irreducibilidad se estableció en el theorem 4.2 y la aperiodicidad en la theorem 4.5. El punto (iii) es el Teorema Ergódico para cadenas de Markov. $\square$

Observación 4.7 (Distribución estacionaria y óptimos globales). El theorem 4.6 garantiza la existencia de π^* , pero no dice cómo está concentrada. En general, π^* no se concentra en poblaciones óptimas: la mutación positiva permite escapar de cualquier estado, incluyendo los óptimos. El AGC ergódico sin elitismo es un explorador permanente del espacio, no un buscador convergente en el sentido clásico.

5 Estados absorbentes y elitismo

5.1 Estados absorbentes en el AGC sin mutación

Definición 5.1 (Estado absorbente). Una población $P^* \in \mathcal{P}_\mu$ es un *estado absorbente* si $T_{P^*, P^*} = 1$, equivalentemente $T_{P^*, Q} = 0$ para todo $Q \neq P^*$.

Proposición 5.2 (Caracterización de estados absorbentes con $p_m = 0$). *Sea el AGC con $p_m = 0$ y $p_c \in [0, 1]$. Una población $P = (x, x, \dots, x)$ homogénea (todos los individuos iguales) es un estado absorbente. Recíprocamente, si $p_c < 1$, toda población absorbente es homogénea.*

Proof. ($\Rightarrow$): Si $P = (x, \dots, x)$, la selección siempre elige x , el cruce de x con x produce x independientemente del punto de corte, y la mutación con $p_m = 0$ no altera nada. Luego $P_{t+1} = P$ con probabilidad 1.

($\Leftarrow$): Si P no es homogénea, existen $x^{(i)} \neq x^{(j)}$. Con $p_c < 1$ y selección proporcional (asumiendo $f > 0$), existe probabilidad positiva de seleccionar $x^{(i)}$ dos veces consecutivas, producir un par no idéntico bajo cruce (o sin cruce), y así la población siguiente difiere de P con probabilidad positiva. $\square$

Observación 5.3. Con $p_m = 0$, el AGC tiene múltiples estados absorbentes (tantos como cromosomas), y la cadena no es irreducible. La convergencia al óptimo global no está garantizada: la cadena puede quedar atrapada en un estado absorbente subóptimo.

5.2 El AGC elitista: cadena absorbente al óptimo

El elitismo de orden $e \geq 1$ copia los e mejores individuos de P_t directamente a P_{t+1} , modificando el kernel de transición. Definimos formalmente:

Definición 5.4 (Kernel elitista). Sea $x^* = \arg \max_{x \in P} f(x)$ el mejor individuo de P (con regla de desempate fija). El kernel del AGC con elitismo de orden 1 es

$$T_{P,Q}^{\text{el}} = \mathbb{P}(\Phi^{\text{el}}(P) = Q),$$

donde $\Phi^{\text{el}}(P)$ se obtiene aplicando Φ a P y reemplazando el individuo de menor aptitud en el resultado por x^* si $f^*(P_{t+1}) < f^*(P_t)$.

La introducción del elitismo rompe la simetría entre estados: la transición de una población con mejor individuo de aptitud f_0 a una población con mejor aptitud $f_1 < f_0$ tiene probabilidad cero.

Definición 5.5 (Orden parcial sobre poblaciones). Definimos la relación de orden parcial $P \preceq Q$ si y sólo si $f^*(P) \leq f^*(Q)$.

Proposición 5.6 (Monotonía de la aptitud máxima con elitismo). Sea el AGC con elitismo de orden $e \geq 1$. Entonces para todo $t \geq 0$,

$$f^*(P_{t+1}) \geq f^*(P_t) \quad \text{c.s.}$$

En particular, el proceso $(f^*(P_t))_{t \geq 0}$ es una submartingala respecto a la filtración natural $\mathcal{F}_t = \sigma(P_0, \dots, P_t)$.

Proof. Por definición de Φ^{el} : si el mejor individuo de P_{t+1} (antes de aplicar el elitismo) tiene aptitud menor que $f^*(P_t)$, este es reemplazado por el mejor de P_t , preservando $f^*(P_{t+1}) \geq f^*(P_t)$. En caso contrario, la aptitud crece o se mantiene por sí misma. $\square$

6 Convergencia al óptimo global

6.1 Convergencia asintótica con elitismo y mutación

Teorema 6.1 (Convergencia global del AGC elitista). Sea $f : \Omega_G \rightarrow \mathbb{R}_{>0}$ y $f_{\max} = \max_{x \in \Omega_G} f(x)$. Supóngase que el AGC se ejecuta con:

- (a) elitismo de orden $e \geq 1$,
- (b) mutación bit a bit con $p_m \in (0, 1)$,
- (c) selección proporcional o por torneo.

Entonces

$$\mathbb{P}\left(\lim_{t \rightarrow \infty} f^*(P_t) = f_{\max}\right) = 1.$$

Proof. La demostración se articula en tres etapas.

Etapas 1: Monotonía. Por el elitismo, $f^*(P_t)$ es no decreciente en t (proposición anterior) y acotada superiormente por $f_{\max}$. Por el teorema de convergencia monótona para procesos, existe el límite $f^* = \lim_{t \rightarrow \infty} f^*(P_t)$ c.s., y $f^* \leq f_{\max}$.

Etapas 2: Accesibilidad uniforme de un cromosoma óptimo. Sea $x^{**} \in \arg \max f$. Como Ω_G y $\mathcal{P}_\mu$ son finitos y $p_m \in (0, 1)$, existe una probabilidad mínima positiva de generar x^{**} en una generación desde cualquier población no óptima. Definimos

$$\alpha := \min_{P \in \mathcal{P}_\mu} \mathbb{P}(x^{**} \in P_{t+1} \mid P_t = P).$$

Esta constante satisface $\alpha > 0$. En efecto, desde cualquier población se puede seleccionar algún individuo con probabilidad positiva, no aplicar cruce con probabilidad positiva y después mutarlo bit a bit hasta x^{**} con probabilidad $p_m^{d_H(x, x^{**})}(1 - p_m)^{\ell - d_H(x, x^{**})} > 0$. Al tomar el mínimo sobre el espacio finito $\mathcal{P}_\mu$, se obtiene una cota uniforme positiva.

Etapas 3: Convergencia con probabilidad 1. Sea

$$\tau = \inf\{t \geq 0 : x^{**} \in P_t\}$$

el tiempo de primera aparición de un óptimo global. Mientras $\tau > t$, la cota anterior implica

$$\mathbb{P}(\tau > t + 1 \mid \tau > t) \leq 1 - \alpha.$$

Por inducción,

$$\mathbb{P}(\tau > t) \leq (1 - \alpha)^t \rightarrow 0.$$

Luego $\mathbb{P}(\tau < \infty) = 1$. Una vez que aparece un óptimo, el elitismo garantiza que la aptitud máxima de la población no vuelve a caer por debajo de $f_{\max}$. Por tanto,

$$\mathbb{P}\left(\lim_{t \rightarrow \infty} f^*(P_t) = f_{\max}\right) = 1.$$

□

Observación 6.2. El Teorema 6.1 es un resultado de convergencia *asintótica*: garantiza que el óptimo será encontrado eventualmente, pero no da una cota sobre el número de generaciones necesarias. La velocidad de convergencia depende de α , que a su vez depende de p_m , ℓ y la distancia entre la población actual y x^{**} .

6.2 No convergencia del AGC ergódico sin elitismo

Proposición 6.3 (Inestabilidad del óptimo sin elitismo). *Sea el AGC sin elitismo con $p_m \in (0, 1)$. Para cualquier población óptima P^{**} (con todos los individuos en $\arg \max f$),*

$$T_{P^{**}, P^{**}} < 1 \quad y \quad \mathbb{P}(f^*(P_t) < f_{\max} \text{ i.o.}) = 1.$$

Proof. Como $p_m \in (0, 1)$, la probabilidad de que al menos un locus mute es $1 - (1 - p_m)^\ell > 0$. Por tanto, existe probabilidad positiva de que P_{t+1} contenga un individuo distinto de x^{**} , lo que puede resultar en $f^*(P_{t+1}) < f_{\max}$. Como la cadena es ergódica, visita todos los estados infinitas veces, en particular estados con aptitud máxima por debajo de $f_{\max}$. □

7 Análisis de la distribución estacionaria

7.1 Caracterización implícita de π^*

Para el AGC ergódico (sin elitismo, $p_m \in (0, 1)$), la distribución estacionaria π^* satisface $\pi^* \mathbf{T} = \pi^*$. No existe en general una fórmula cerrada para π^* ; sin embargo, pueden obtenerse caracterizaciones cualitativas.

Proposición 7.1 (Positividad de la masa estacionaria). *Para el AGC ergódico, la distribución estacionaria satisface*

$$\pi^*(Q) > 0 \quad \forall Q \in \mathcal{P}_\mu.$$

Proof. Como la cadena es finita, irreducible y aperiódica, posee una única distribución estacionaria π^* . En una cadena finita irreducible, todos los estados pertenecen a la misma clase comunicante positiva recurrente; por tanto, la medida estacionaria asigna masa estrictamente positiva a cada estado. □

Observación 7.2. La computación directa de π^* es intratable para instancias reales: la matriz $\mathbf{T}$ tiene dimensión $|\Sigma|^{\mu^\ell} \times |\Sigma|^{\mu^\ell}$, lo que excede cualquier capacidad de almacenamiento. El valor práctico del análisis markoviano reside en las propiedades cualitativas (ergodicidad, convergencia, tasas), no en la computación explícita de π^* .

7.2 Relación entre π^* y la aptitud

Una pregunta natural es: ¿en qué medida se concentra π^* en poblaciones de alta aptitud? La siguiente proposición da una respuesta parcial.

Observación 7.3 (Sesgo de la distribución estacionaria hacia alta aptitud). Sea $\mathcal{G}_k = \{P \in \mathcal{P}_\mu : f^*(P) \geq k\}$ el conjunto de poblaciones con mejor individuo de aptitud al menos k . La masa $\pi^*(\mathcal{G}_k)$ cuantifica la fracción de largo plazo que el AGC ergódico pasa en poblaciones cuya mejor aptitud es al menos k .

En general no existe una cota universal simple para $\pi^*(\mathcal{G}_k)$ que dependa solo de p_m , p_c y k : también intervienen la función de aptitud, el operador de selección y la geometría del espacio genotípico. Lo que sí puede afirmarse, por la positividad anterior, es que

$$0 < \pi^*(\mathcal{G}_k) < 1$$

si tanto $\mathcal{G}_k$ como su complemento son no vacíos. La distribución estacionaria puede estar sesgada hacia poblaciones de alta aptitud, pero dicho sesgo debe analizarse caso por caso.

8 Tasas de convergencia y mezcla

8.1 Tiempo de mezcla

Definición 8.1 (Distancia de variación total y tiempo de mezcla). Sea $\mu_t(\cdot) = \mathbb{P}(P_t = \cdot \mid P_0)$ la distribución de la cadena en el tiempo t . La *distancia de variación total* respecto a π^* es

$$d_{\text{TV}}(t) = \max_{P_0 \in \mathcal{P}_\mu} \|\mu_t - \pi^*\|_{\text{TV}} = \max_{P_0 \in \mathcal{P}_\mu} \frac{1}{2} \sum_{Q \in \mathcal{P}_\mu} \left| T_{P_0, Q}^{(t)} - \pi^*(Q) \right|.$$

El *tiempo de mezcla* con precisión $\varepsilon > 0$ es

$$t_{\text{mix}}(\varepsilon) = \min\{t \geq 0 : d_{\text{TV}}(t) \leq \varepsilon\}.$$

Teorema 8.2 (Convergencia exponencial al equilibrio). *Para el AGC ergódico, existen constantes $C > 0$ y $\rho \in (0, 1)$ tales que*

$$d_{\text{TV}}(t) \leq C \cdot \rho^t \quad \forall t \geq 0.$$

En particular,

$$t_{\text{mix}}(\varepsilon) \leq \left\lceil \frac{\log(C/\varepsilon)}{\log(1/\rho)} \right\rceil.$$

Si, adicionalmente, la cadena es reversible, puede tomarse ρ relacionado con el módulo del segundo valor propio dominante.

Proof. Toda cadena de Markov finita, irreducible y aperiódica converge geométricamente a su distribución estacionaria. En el caso reversible, esta tasa se expresa de forma natural en términos del segundo valor propio en valor absoluto. En el caso no reversible, la tasa puede describirse mediante el radio espectral subdominante, valores singulares o la forma de Jordan de la matriz de transición; por ello se escribe genéricamente como $\rho \in (0, 1)$. $\square$

8.2 El segundo valor propio y la brecha espectral

Definición 8.3 (Brecha espectral). Cuando la cadena es reversible, sea $1 = \lambda_1 > |\lambda_2| \geq \dots \geq |\lambda_{|\mathcal{P}_\mu|}|$ el orden de los valores propios de $\mathbf{T}$ en valor absoluto. La *brecha espectral* se define como

$$\text{gap}(\mathbf{T}) = 1 - |\lambda_2|.$$

Para cadenas no reversibles, esta noción debe sustituirse o complementarse con cantidades como el radio espectral subdominante o la brecha absoluta asociada a la multiplicación $\mathbf{T}^*\mathbf{T}$.

Observación 8.4 (Significado de la brecha espectral). Un valor de $\text{gap}(\mathbf{T})$ cercano a 1 (i.e., $\lambda_2 \approx 0$) indica convergencia rápida: pocas generaciones son suficientes para que la distribución de P_t se aproxime a π^* . Una brecha espectral pequeña (i.e., $\lambda_2 \approx 1$) indica mezcla lenta: el algoritmo tarda muchas generaciones en explorar el espacio de búsqueda. La brecha espectral depende de todos los parámetros del AGC (μ , p_c , p_m , operador de selección) y no tiene expresión cerrada en general.

8.3 Relación entre tasa de mutación y mezcla

Proposición 8.5 (Brecha espectral del kernel puro de mutación). *Para el kernel de mutación bit a bit sobre $\{0, 1\}^\ell$, sin selección ni cruce, la brecha espectral es*

$$\text{gap}(T^M) = 1 - |1 - 2p_m|.$$

En particular, es creciente en p_m para $p_m \in (0, 1/2)$.

Esbozo. El kernel $T_{x,y}^M = p_m^{d_H(x,y)}(1 - p_m)^{\ell - d_H(x,y)}$ es el de una caminata aleatoria en el cubo de Hamming $\{0, 1\}^\ell$. Para esta caminata, los valores propios son conocidos:

$$\lambda_k = (1 - 2p_m)^k, \quad k = 0, 1, \dots, \ell.$$

Por tanto el segundo valor propio en valor absoluto es $|1 - 2p_m|$ y la brecha es $1 - |1 - 2p_m|$. $\square$

Observación 8.6. La theorem 8.5 muestra un compromiso fundamental: una tasa de mutación alta acelera la mezcla (exploración), pero destruye los bloques constructores identificados por el algoritmo, perjudicando la explotación. Este compromiso no tiene solución universal, y justifica las estrategias de *mutación adaptativa* en variantes modernas.

9 Cadenas de Markov reducidas: proyecciones y lumpability

Dado que el espacio $\mathcal{P}_\mu$ es astronómicamente grande, es natural estudiar proyecciones de la cadena que capturen el comportamiento relevante con menos estados.

9.1 Proyección sobre la aptitud máxima

Definición 9.1 (Cadena proyectada sobre la aptitud máxima). Sea $F^* : \mathcal{P}_\mu \rightarrow \mathcal{F}^* \subseteq \mathbb{R}_{>0}$ la aplicación $P \mapsto f^*(P)$. La *cadena proyectada* $(\hat{f}_t)_{t \geq 0}$ es el proceso

$$\hat{f}_t = f^*(P_t).$$

Observación 9.2. La cadena proyectada $(\hat{f}_t)$ no es en general markoviana, porque la distribución de $f^*(P_{t+1})$ puede depender del estado interno completo P_t , no solo de $f^*(P_t)$. Sin embargo, con elitismo, $(\hat{f}_t)$ es submartingala (como ya se estableció), lo que da información sobre su comportamiento.

9.2 Lumpability y particiones compatibles

Definición 9.3 (Lumpability fuerte). Sea $\{C_1, \dots, C_k\}$ una partición de $\mathcal{P}_\mu$. La cadena es *fuertemente lumpable* respecto a esta partición si para todo i, j y todo $P, P' \in C_i$,

$$\sum_{Q \in C_j} T_{P,Q} = \sum_{Q \in C_j} T_{P',Q}.$$

En este caso, la cadena reducida $(\hat{P}_t)_{t \geq 0}$ sobre las clases $\{C_1, \dots, C_k\}$ es una cadena de Markov bien definida.

Proposición 9.4 (Monotonía de la partición por aptitud máxima). *Consideremos la partición de $\mathcal{P}_\mu$ por el valor de la aptitud máxima: $C_k = \{P \in \mathcal{P}_\mu : f^*(P) = k\}$ para cada k en el rango de f^* . Con elitismo, la probabilidad de transición de C_k a C_j con $j < k$ es cero:*

$$\sum_{Q \in C_j} T_{P,Q}^{\text{el}} = 0 \quad \text{para todo } P \in C_k, j < k.$$

Esto expresa una propiedad de monotonía de la aptitud máxima, pero no implica, por sí solo, lumpability fuerte ni que la proyección sobre $f^(P_t)$ sea una cadena de Markov.*

10 Tiempo esperado de primera visita al óptimo

Definición 10.1 (Tiempo de primer éxito). Sea $\mathcal{O} = \{P \in \mathcal{P}_\mu : f^*(P) = f_{\max}\}$ el conjunto de poblaciones óptimas. El *tiempo de primer éxito* desde P_0 es la variable aleatoria

$$\tau = \min\{t \geq 0 : P_t \in \mathcal{O}\}.$$

Teorema 10.2 (Finitud del tiempo esperado de primer éxito). *Bajo las hipótesis del theorem 6.1, $\mathbb{E}_{P_0}[\tau] < \infty$ para todo $P_0 \in \mathcal{P}_\mu$.*

Proof. Sea $\alpha = \min_{P \in \mathcal{P}_\mu} \mathbb{P}(\tau \leq 1 \mid P_0 = P) > 0$, que existe y es positivo por la accesibilidad en un paso (demostrada en el theorem 4.2; con elitismo, una vez alcanzado $\mathcal{O}$ no se abandona). Entonces

$$\mathbb{P}(\tau > n) \leq (1 - \alpha)^n,$$

y por tanto

$$\mathbb{E}[\tau] = \sum_{n=0}^{\infty} \mathbb{P}(\tau > n) \leq \sum_{n=0}^{\infty} (1 - \alpha)^n = \frac{1}{\alpha} < \infty.$$

□

10.1 Cota superior del tiempo esperado

Proposición 10.3 (Cota geométrica para el tiempo esperado). *Bajo las condiciones del theorem 10.2, con α definido como la probabilidad mínima en un paso de generar al menos un individuo óptimo,*

$$\mathbb{E}_{P_0}[\tau] \leq \frac{1}{\alpha} = (p_m^{d^*}(1 - p_m)^{\ell - d^*})^{-1},$$

donde $d^* = \max_{x \in P_0} d_H(x, x^{**})$ es la distancia máxima de Hamming entre los individuos iniciales y el óptimo.

Observación 10.4. Esta cota es *pesimista*: crece exponencialmente con d^* y ℓ . Refleja el peor caso de una búsqueda completamente aleatoria por mutación. En práctica, la selección y el cruce aceleran considerablemente la convergencia al orientar la búsqueda hacia regiones prometedoras.

11 Comportamiento asintótico de la distribución de la aptitud

11.1 Concentración alrededor del óptimo con elitismo

Con el AGC elitista, la aptitud máxima $f^*(P_t)$ converge a $f_{\max}$ con probabilidad 1 (Teorema 6.1). La siguiente proposición analiza la *velocidad* de esta convergencia.

Proposición 11.1 (Convergencia exponencialmente rápida en probabilidad). *Bajo las hipótesis del theorem 6.1,*

$$\mathbb{P}(f^*(P_t) < f_{\max}) \leq (1 - \alpha)^t,$$

donde $\alpha > 0$ es la probabilidad mínima de generar el óptimo en un paso.

Proof. Sea $B_t = \{f^*(P_t) < f_{\max}\}$. Por el elitismo, $B_{t+1} \subseteq B_t$, es decir, B_t es una sucesión decreciente de eventos. Además, $\mathbb{P}(B_{t+1} \mid B_t) \leq 1 - \alpha$, por lo que $\mathbb{P}(B_t) \leq (1 - \alpha)^t \rightarrow 0$. $\square$

11.2 Distribución asintótica de la aptitud media

Para el AGC ergódico, la distribución límite de la aptitud media $\bar{f}(P_t)$ converge a su valor bajo la distribución estacionaria:

Proposición 11.2. *Para el AGC ergódico,*

$$\bar{f}(P_t) \xrightarrow{t \rightarrow \infty} \bar{f}_{\infty} = \sum_{P \in \mathcal{P}_{\mu}} \pi^*(P) \bar{f}(P) \quad c.s.$$

El valor $\bar{f}_{\infty}$ depende de todos los parámetros del AGC y satisface $\bar{f}_{\infty} < f_{\max}$ en general (la distribución estacionaria no concentra toda su masa en el óptimo).

12 Conexión con el Teorema de los Esquemas

El Teorema de los Esquemas (Holland, 1975) puede reinterpretarse en el lenguaje de las cadenas de Markov como una cota sobre la *esperanza condicional* del número de representantes de un esquema.

Teorema 12.1 (Reformulación markoviana del Teorema de los Esquemas). *Sea $H \in \hat{\Sigma}^\ell$ un esquema y $m(H, t) = |\{i : x_t^{(i)} \in H\}|$ el número de representantes en la generación t . Entonces, el Teorema de los Esquemas (Teorema 7.8 de las notas base) afirma que la siguiente desigualdad para la esperanza condicional se satisface:*

$$\mathbb{E}[m(H, t+1) \mid P_t] \geq m(H, t) \cdot \frac{\bar{f}(H, t)}{\bar{f}(P_t)} \cdot \left(1 - p_c \frac{\delta(H)}{\ell - 1}\right) \cdot (1 - p_m)^{o(H)}.$$

Esta es una cota sobre la derivada promedio del proceso $m(H, \cdot)$ visto como función de la cadena de Markov (P_t) .

Observación 12.2. El Teorema de los Esquemas *no* es un resultado sobre valores propios ni sobre la distribución estacionaria. Es una cota sobre la dinámica transitoria del proceso, válida generación a generación. Esto lo distingue de los resultados de convergencia presentados en las secciones anteriores.

Corolario 12.3 (Esquemas como funciones de Lyapunov). *Si $\bar{f}(H, t) \geq (1 + \varepsilon)\bar{f}(P_t)$ y los factores de disrupción son suficientemente pequeños (específicamente, $p_c \frac{\delta(H)}{\ell - 1} + p_m o(H) \leq \varepsilon/2$), entonces*

$$\mathbb{E}[m(H, t+1) \mid P_t] \geq \left(1 + \frac{\varepsilon}{2}\right) m(H, t).$$

Es decir, $m(H, t)$ se comporta como una subfunción de Lyapunov: crece en esperanza cuando el esquema es suficientemente bueno y robusto. Su eventual disminución (por pérdida de diversidad o convergencia del algoritmo) marca el agotamiento del régimen de crecimiento.

13 El modelo de dos escalas temporales

Una perspectiva unificadora combina la dinámica intra-poblacional (rápida) con la dinámica inter-régimen (lenta) mediante técnicas de separación de escalas.

Definición 13.1 (Partición en regiones de aptitud). Sea $0 = k_0 < k_1 < \dots < k_m = f_{\max}$ una partición de los valores de aptitud. Define los conjuntos de poblaciones

$$\mathcal{R}_j = \{P \in \mathcal{P}_\mu : k_{j-1} < f^*(P) \leq k_j\}, \quad j = 1, \dots, m.$$

Teorema 13.2 (Modelo de dos escalas para el AGC elitista). *Bajo el AGC elitista con p_m pequeño, la dinámica puede aproximarse en dos escalas:*

- (i) **Escala rápida (intra-región):** *Dada una región $\mathcal{R}_j$, la cadena restringida a $\mathcal{R}_j$ mezcla en un tiempo $O(\log |\mathcal{R}_j| / \text{gap}(\mathbf{T}|\mathcal{R}_j))$.*
- (ii) **Escala lenta (inter-región):** *Las transiciones de $\mathcal{R}_j$ a $\mathcal{R}_{j+1}$ ocurren con probabilidad del orden de*

$$q_j \sim p_m^{d_j} (1 - p_m)^{\ell - d_j},$$

donde d_j es la distancia típica de Hamming al umbral k_{j+1} . El tiempo esperado de avance de región es $O(1/q_j)$.

Por tanto, el tiempo total esperado para alcanzar $\mathcal{R}_m$ (el óptimo) es

$$\mathbb{E}[\tau] \lesssim \sum_{j=1}^m \frac{1}{q_j}.$$

Observación 13.3. El Teorema 13.2 es una aproximación; su rigor depende de que las escalas temporales sean efectivamente separadas ($q_j \ll \text{gap}(\mathbf{T}|\mathcal{R}_j)$). Proporciona sin embargo una intuición útil: el AGC avanza a través de regiones de aptitud creciente, y el cuello de botella está en las transiciones entre regiones, que requieren la generación de individuos significativamente mejores.

14 Síntesis: cuadro comparativo de los regímenes del AGC

Configuración	Irreducibilidad	Ergodicidad	Convergencia al óptimo
$p_m = 0$, sin elitismo	No (estados absorbentes)	No	No garantizada
$p_m \in (0, 1)$, sin elitismo	Sí	Sí	No (cadena ergódica, no converge)
$p_m = 0$, con elitismo	No (estados absorbentes)	No	Solo si la selección alcanza el óptimo
$p_m \in (0, 1)$, con elitismo	No en la cadena completa; cerradas por elitismo	No en general	Sí, con probabilidad 1

15 Conclusiones

El encuadre del AGC como cadena de Markov proporciona una base rigurosa para responder las preguntas más fundamentales sobre su comportamiento. Los resultados principales de este documento pueden resumirse así:

1. El AGC define una cadena de Markov homogénea en el espacio finito $\mathcal{P}_\mu$, cuyo kernel de transición se factoriza en tres componentes correspondientes a selección, cruce y mutación (theorem 3.1, theorem 3.2).
2. Con $p_m \in (0, 1)$ y sin elitismo, la cadena es ergódica: admite una única distribución estacionaria π^* y converge a ella geométricamente, pero *no* converge al óptimo (theorem 4.6).
3. El elitismo introduce monotonía de la aptitud máxima y, combinado con $p_m \in (0, 1)$, garantiza convergencia al óptimo global con probabilidad 1 (theorem 6.1).

4. La velocidad de convergencia está controlada por la brecha espectral de $\mathbf{T}$ y por la probabilidad mínima α de generar el óptimo en un paso (theorem 8.2, theorem 10.2).
5. El Teorema de los Esquemas es una cota sobre la esperanza condicional del número de representantes de un esquema, interpretable como una condición de subfunción de Lyapunov para la dinámica transitoria (theorem 12.1, theorem 12.3).
6. El modelo de dos escalas temporales separa la dinámica rápida intra-región de la lenta inter-región, ofreciendo una estimación intuitiva del tiempo total de convergencia (theorem 13.2).

Estos resultados ilustran cómo la teoría de procesos estocásticos proporciona el lenguaje adecuado para el análisis riguroso de los algoritmos genéticos, y abre la puerta a refinamientos posteriores: cotas más ajustadas del tiempo de mezcla, análisis de la brecha espectral en función de los parámetros del AGC, y extensiones a espacios de búsqueda continuos o de dimensión variable.

Referencias

- [1] Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- [2] Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- [3] Rudolph, G. (1994). Convergence analysis of canonical genetic algorithms. *IEEE Transactions on Neural Networks*, 5(1), 96–101.
- [4] Nix, A. E., & Vose, M. D. (1992). Modeling genetic algorithms with Markov chains. *Annals of Mathematics and Artificial Intelligence*, 5(1), 79–88.
- [5] Vose, M. D. (1999). *The Simple Genetic Algorithm: Foundations and Theory*. MIT Press.
- [6] Suzuki, J. (1995). A Markov chain analysis on simple genetic algorithms. *IEEE Transactions on Systems, Man, and Cybernetics*, 25(4), 655–659.
- [7] Levin, D. A., Peres, Y., & Wilmer, E. L. (2017). *Markov Chains and Mixing Times* (2nd ed.). American Mathematical Society.
- [8] Wolpert, D. H., & Macready, W. G. (1997). No Free Lunch Theorems for Optimization. *IEEE Transactions on Evolutionary Computation*, 1(1), 67–82.
- [9] Cerf, R. (1998). Asymptotic convergence of genetic algorithms. *Advances in Applied Probability*, 30(2), 521–550.
- [10] Iosifescu, M. (1980). *Finite Markov Processes and Their Applications*. Wiley.