
Algoritmos Genéticos dentro de la Ruta de Formación hacia Modelos de Lenguaje

Fundamentos matemáticos, optimización, aprendizaje automático e inteligencia artificial

Estudiante: Luis Alfredo Ramírez Maza

Materia: Algoritmos Genéticos

Profesor: César Galindo

Repositorio del profesor: github.com/ZesarGal

Evidencia de aprendizaje y organización conceptual del curso

1. Introducción

El repositorio académico del profesor César Galindo reúne materiales de álgebra lineal, probabilidad, modelos estocásticos, aprendizaje automático e inteligencia artificial. Estos contenidos pueden entenderse como una ruta progresiva de formación hacia áreas modernas de la inteligencia artificial y, en última instancia, hacia el estudio de modelos de lenguaje.

La idea de una *Ruta LLM* no consiste únicamente en estudiar directamente transformers o modelos generativos. Antes de llegar a ellos es necesario dominar los fundamentos matemáticos y computacionales que permiten representar información, modelar incertidumbre, optimizar funciones y construir sistemas capaces de aprender a partir de datos.

Dentro de esta ruta, la materia de Algoritmos Genéticos ocupa un lugar importante. Los algoritmos genéticos son métodos de búsqueda y optimización inspirados en la evolución natural. Su funcionamiento combina conceptos de probabilidad, procesos estocásticos, representación matemática, programación y evaluación de soluciones.

Idea central

Los algoritmos genéticos funcionan como un puente entre los fundamentos matemáticos y las aplicaciones de inteligencia artificial, debido a que permiten resolver problemas complejos de optimización en espacios donde los métodos analíticos tradicionales pueden ser insuficientes.

2. Organización conceptual de la Ruta LLM

Los repositorios del profesor pueden agruparse en varias capas conceptuales. Cada capa proporciona herramientas que sirven como fundamento para la siguiente.

2.1. Nivel I: Álgebra lineal

El álgebra lineal permite representar objetos mediante vectores, matrices y transformaciones. En inteligencia artificial, los datos suelen codificarse como vectores de características, mientras que los modelos realizan operaciones matriciales para transformar dichas representaciones.

Entre los conceptos más relevantes se encuentran:

- Espacios vectoriales y subespacios.
- Bases, dimensión y cambios de coordenadas.
- Transformaciones lineales.
- Eigenvalores y eigenvectores.
- Matrices de covarianza.
- Proyecciones y reducción de dimensionalidad.

Estos elementos aparecen directamente en técnicas como el Análisis de Componentes Principales, los sistemas de recomendación, los embeddings y las redes neuronales.

2.2. Nivel II: Probabilidad y estadística

La probabilidad permite modelar fenómenos aleatorios e incertidumbre. Esta capa es fundamental para comprender tanto los algoritmos genéticos como los modelos de aprendizaje automático.

En un algoritmo genético, la selección, el cruce y la mutación incorporan mecanismos aleatorios. Por ello, la evolución de una población no es completamente determinista, sino que depende de distribuciones de probabilidad y decisiones estocásticas.

La estadística, por su parte, permite evaluar resultados, estimar parámetros, medir variabilidad y comparar el comportamiento de diferentes soluciones.

2.3. Nivel III: Modelos y procesos estocásticos

Un proceso estocástico describe la evolución de un sistema cuyos estados cambian con cierto grado de aleatoriedad. La población de un algoritmo genético puede interpretarse como un sistema dinámico que cambia generación tras generación.

En cada iteración:

- se evalúa la calidad de los individuos;
- se seleccionan los individuos con mejor aptitud;
- se generan nuevos individuos;
- se introducen perturbaciones mediante mutación;
- se produce una nueva distribución de soluciones.

Esta evolución puede estudiarse desde una perspectiva probabilística y, en ciertos casos, mediante herramientas relacionadas con cadenas de Markov.

2.4. Nivel IV: Aprendizaje automático

El aprendizaje automático reúne técnicas que permiten encontrar patrones, predecir resultados y optimizar decisiones a partir de datos.

En los repositorios del profesor aparecen temas como:

- Regresión Ridge y Lasso.
- Árboles de regresión.
- K-Means.
- Análisis de Componentes Principales.
- Redes neuronales.
- Algoritmos genéticos.

Los algoritmos genéticos complementan estas técnicas porque pueden utilizarse para seleccionar variables, ajustar hiperparámetros, encontrar arquitecturas, optimizar funciones objetivo o resolver problemas multimodales.

2.5. Nivel V: Inteligencia artificial

La inteligencia artificial integra técnicas de representación, aprendizaje, búsqueda, razonamiento y optimización.

Los algoritmos genéticos pertenecen al área conocida como *computación evolutiva*, la cual forma parte de la inteligencia computacional. A diferencia de los métodos que buscan una solución mediante derivadas o reglas deterministas, los algoritmos genéticos mantienen una población de soluciones y exploran simultáneamente diferentes regiones del espacio de búsqueda.

Esta característica permite aplicarlos en problemas donde:

- la función objetivo es no lineal;
- existen múltiples óptimos locales;
- no se dispone de derivadas;
- las variables son discretas o mixtas;
- el espacio de soluciones es muy grande.

3. Los Algoritmos Genéticos como método de optimización

Un algoritmo genético trabaja con una población de individuos. Cada individuo representa una posible solución a un problema.

De manera general, el procedimiento sigue las siguientes etapas:

1. **Inicialización:** se genera una población inicial de soluciones.
2. **Evaluación:** se calcula la función de aptitud o *fitness*.
3. **Selección:** se eligen individuos con base en su calidad.
4. **Cruce:** se combinan características de dos o más individuos.
5. **Mutación:** se modifican aleatoriamente algunos componentes.
6. **Reemplazo:** se construye una nueva generación.
7. **Criterio de paro:** el proceso termina al alcanzar una condición establecida.

Si un individuo se representa mediante un vector

$$x = (x_1, x_2, \dots, x_n),$$

la función de aptitud puede escribirse como

$$f(x) : \mathbb{R}^n \longrightarrow \mathbb{R}.$$

El objetivo puede consistir en encontrar

$$x^* = \arg \max_{x \in \Omega} f(x)$$

o, de forma equivalente, minimizar una función de costo.

Conexión dentro de la ruta

La formulación anterior muestra que los algoritmos genéticos no son únicamente una simulación biológica. Son métodos matemáticos de optimización que emplean mecanismos probabilísticos para explorar un espacio de soluciones.

4. Relación con probabilidad y cambio de medida

La selección modifica la distribución de individuos de una población. Antes de la selección, las soluciones pueden encontrarse distribuidas ampliamente en el espacio de búsqueda. Después de evaluar la aptitud, las regiones con mejores soluciones reciben mayor peso.

Si la población inicial sigue una distribución P , el proceso de selección puede interpretarse como una transformación hacia otra distribución Q , en la que los individuos con mayor aptitud tienen mayor probabilidad de aparecer.

De manera conceptual, puede escribirse

$$Q(x) \propto f(x)P(x),$$

donde $f(x)$ representa el peso asociado a la aptitud.

Esta interpretación conecta los algoritmos genéticos con ideas de cambio de medida, muestreo por importancia y máxima verosimilitud. La selección favorece regiones de alta calidad, mientras que la mutación evita que la búsqueda quede limitada a una sola zona.

En problemas de estimación, un individuo puede representar un vector de parámetros

$$\theta = (\theta_1, \theta_2, \dots, \theta_d),$$

y la función de aptitud puede definirse mediante la log-verosimilitud:

$$\text{fitness}(\theta) = \ell(\theta) = \sum_{i=1}^n \log f_{\theta}(x_i).$$

En este caso, el algoritmo genético busca parámetros que hagan más probables los datos observados.

5. Relación con Álgebra Lineal y PCA

El Análisis de Componentes Principales busca direcciones que maximicen la varianza de un conjunto de datos. Si S es una matriz de covarianza, el primer componente principal puede obtenerse resolviendo

$$w^* = \arg \max_{\|w\|=1} w^T S w.$$

Tradicionalmente, este problema se resuelve mediante eigenvalores y eigenvectores. Sin embargo, también puede formularse como un problema de optimización para un algoritmo genético.

En ese contexto:

- cada individuo representa una dirección w ;
- la aptitud se define como $w^T S w$;
- la restricción $\|w\| = 1$ puede imponerse mediante normalización;
- la población busca direcciones que expliquen la mayor varianza.

Los algoritmos genéticos pueden resultar útiles cuando se desea incorporar restricciones adicionales, robustez frente a valores atípicos o criterios que dificultan una solución analítica directa.

Esta conexión muestra la relación entre tres bloques fundamentales de la ruta:

$$\text{Álgebra Lineal} \longrightarrow \text{Optimización} \longrightarrow \text{Algoritmos Genéticos}.$$

6. Relación con Machine Learning

Los algoritmos genéticos pueden integrarse con técnicas de aprendizaje automático de diferentes maneras.

6.1. Selección de variables

Cuando una base de datos contiene muchas variables, un individuo puede codificar qué variables deben incluirse en un modelo. Por ejemplo,

$$x = (1, 0, 1, 1, 0)$$

puede indicar que se seleccionan la primera, tercera y cuarta variable.

La función de aptitud puede combinar precisión predictiva y complejidad:

$$\text{fitness}(x) = \text{Accuracy}(x) - \lambda \cdot \text{Complexity}(x).$$

6.2. Optimización de hiperparámetros

Los algoritmos genéticos pueden buscar valores adecuados para parámetros como:

- profundidad de un árbol;
- número de grupos en K-Means;
- parámetros de regularización;
- tasa de aprendizaje;
- número de capas o neuronas;
- parámetros de otros algoritmos evolutivos.

6.3. Optimización multimodal

En algunos problemas existen diferentes soluciones de calidad semejante. Un algoritmo genético puede mantener diversidad y encontrar varias regiones prometedoras del espacio de búsqueda.

Esto es especialmente relevante cuando el objetivo no es encontrar una única solución, sino identificar múltiples configuraciones posibles.


7. Ubicación dentro de la Ruta hacia LLM

Los modelos de lenguaje modernos requieren una combinación de conocimientos matemáticos, estadísticos y computacionales.

Aunque los algoritmos genéticos no constituyen por sí mismos un modelo de lenguaje, su estudio desarrolla capacidades necesarias para comprender sistemas modernos de inteligencia artificial:

- representación de soluciones mediante vectores;
- formulación de funciones objetivo;
- búsqueda en espacios de alta dimensión;
- optimización de parámetros;
- análisis de incertidumbre;
- diseño de experimentos computacionales;
- evaluación y comparación de resultados.

La ruta conceptual puede representarse de la siguiente manera:



En esta arquitectura, los algoritmos genéticos se sitúan como una herramienta de optimización que conecta la base probabilística y matemática con las aplicaciones de Machine Learning e inteligencia artificial.

8. Evidencia de aprendizaje

Como evidencia del trabajo realizado durante la materia, se presenta un repositorio académico que reúne materiales relacionados con Algoritmos Genéticos.

El repositorio incluye:

- notas teóricas sobre algoritmos genéticos;
- notebooks de implementación;
- experimentos computacionales;
- aplicaciones de optimización;
- material sobre optimización multimodal;
- presentación del curso;
- documentación de los avances realizados.

Repositorio del estudiante

<https://github.com/mazzarluis17-jpg/Algoritmos-Gen-ticos->

La organización del repositorio permite consultar tanto los fundamentos teóricos como las implementaciones y resultados obtenidos. De esta forma, el GitHub funciona como evidencia del proceso de aprendizaje y como portafolio académico.

9. Conclusiones

La materia de Algoritmos Genéticos se integra de manera natural dentro de una ruta de formación hacia la inteligencia artificial y los modelos de lenguaje.

Su estudio requiere conocimientos de álgebra lineal para representar soluciones, de probabilidad para comprender los operadores aleatorios y de optimización para formular la búsqueda de mejores individuos.

Asimismo, los algoritmos genéticos se relacionan directamente con herramientas de Machine Learning, ya que pueden emplearse para seleccionar variables, ajustar hiperparámetros, optimizar modelos y explorar espacios complejos de soluciones.

El análisis de los repositorios del profesor muestra una trayectoria que parte de los fundamentos matemáticos y avanza hacia aplicaciones computacionales. En esta trayectoria, los Algoritmos Genéticos constituyen un vínculo entre la teoría y la resolución práctica de problemas.

Por lo tanto, el curso no debe interpretarse como un tema aislado, sino como una parte de una arquitectura más amplia de aprendizaje. Su principal aportación consiste en desarrollar una forma de pensamiento basada en poblaciones, búsqueda, adaptación, evaluación y optimización, conceptos que también aparecen en diversas áreas de la inteligencia artificial moderna.

Referencias y materiales consultados

Referencias

- [1] C. Galindo, *Repositorio académico ZesarGal*. Disponible en: <https://github.com/ZesarGal>.
- [2] C. Galindo, *Mis notas de Lineal*. Material sobre espacios vectoriales, transformaciones lineales, eigenvalores, diagonalización y aplicaciones en inteligencia artificial.
- [3] C. Galindo, *Análisis por Componentes Principales*. Material sobre reducción de dimensionalidad, optimización, eigenvalores y aplicaciones en aprendizaje automático.
- [4] C. Galindo, *Cambio de Medida en Probabilidad*. Material sobre la integral de Lebesgue, el teorema de Radon–Nikodym, máxima verosimilitud, algoritmos genéticos y PCA.
- [5] J. H. Holland, *Adaptation in Natural and Artificial Systems*. University of Michigan Press, 1975.
- [6] D. E. Goldberg, *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, 1989.